

Politechnika Śląska
Wydział Automatyki, Elektroniki i Informatyki
Kierunek Informatyka
Studia stacjonarne II stopnia

Praca dyplomowa magisterska

**Analiza porównawcza algorytmów
metaheurystycznych do
rozwiązywania wybranego problemu
optymalizacyjnego**

Kierujący projektem:
dr inż. Henryk Josiński

Autor:
Sebastian Nalepka

Gliwice 2017

Spis treści

Wstęp	3
1. Wybór badanego problemu optymalizacji	5
1.1. Opis minimalizacji funkcji ciągłych wielu zmiennych	5
1.2. Funkcje testowe	5
1.2.1. Funkcja Bohachevsky'ego 1	6
1.2.2. Funkcja Colville'a	6
1.2.3. Funkcja Ackley'a	6
1.2.4. Funkcja Eggholdera	7
1.2.5. Funkcja Rosenbrocka	7
1.2.6. Funkcja Griewanka	7
2. Metody rozwiązania wybranego problemu optymalizacji	9
2.1. Algorytmy dokładne	9
2.2. Metaheurystyki optymalizacyjne	9
2.2.1. Metoda optymalizacji rojem cząstek	10
2.2.2. Symulowane wyżarzanie	11
2.2.3. Algorytm genetyczny	12
3. Automatyzacja przeprowadzanych badań	17
4. Wykorzystane rozwiązania technologiczne	19
4.1. Zastosowane technologie	19
4.1.1. .NET Framework/C#	19
4.1.2. WPF / XAML	20
4.1.3. TSQL	20
4.2. Zastosowane narzędzia	21
4.2.1. Matlab	21
4.2.2. SQL Server Management Studio 17	21
4.2.3. Visual Studio 2015	22
4.2.4. Resharper	22

4.3. Wykorzystane biblioteki zewnętrzne	23
4.3.1. Matlab Application Type Library v.1.0	23
5. Architektura budowanej aplikacji	25
5.1. Architektura aplikacji	25
5.1.1. Wzorce architektoniczne oprogramowania	25
5.1.2. Zastosowany wzorzec architektoniczny – MVVM	26
5.1.3. Model aplikacji	27
5.2. Architektura bazy danych	29
5.2.1. Microsoft SQL Server – użyty system zarządzania bazą danych	30
5.2.2. Budowa bazy danych użytej w projekcie	30
5.3. Komunikacja bazy danych z projektem programistycznym	33
5.3.1. Mapowanie obiektowo-relacyjne	33
5.3.2. Zastosowane narzędzie ORM – Entity Framework	34
5.4. Komunikacja Matlaba z projektem programistycznym	35
6. Badania eksperymentalne	37
6.1. Metody porównawcze wybranych algorytmów	37
6.2. Opis przeprowadzonych badań	37
6.2.1. Skalowanie algorytmów	37
6.2.2. Przeprowadzenie doświadczeń w zaimplementowanym środowisku testowym	38
6.3. Wyniki doświadczeń dla zadanych funkcji testowych	39
6.3.1. Funkcja Bohachevsky’ego 1	39
6.3.2. Funkcja Colville’a	45
6.3.3. Funkcja Ackley’a	51
6.3.4. Funkcja Eggholdera	57
6.3.5. Funkcja Rosenbrocka	63
6.3.6. Funkcja Griewanka	69
6.3.7. Podsumowanie doświadczeń	75
7. Wnioski	77

Wstęp

W otaczającym nas świecie obecnych jest wiele problemów, z którymi zmagają się ludzie. Część z nich jest problemami prostymi, do rozwiązania których wystarczy wyłącznie nieduży nakład czasu. Istnieją jednak problemy trudniejsze, które wymagają długotrwałych przemyśleń i obliczeń po których nie zawsze otrzymujemy najlepsze rozwiązanie. Do prostych problemów możemy zaliczyć codzienne decyzje podejmowane przez każdego człowieka. Dla przykładu jeśli chcemy dojechać z punktu A do punktu B komunikacją miejską, wystarczy, że sprawdzimy rozkład jazdy i wybierzemy połączenie, które będzie pasowało nam w kontekście godziny przyjazdu na dane miejsce. Przedstawiony problem posiada z gołą inną skalę trudności ze strony przewoźnika. Wyznaczenie optymalnych tras przewozowych dla określonej liczby środków transportu, w celu obsłużenia danego zbioru klientów, którzy rozlokowani są w różnych punktach jest kwestią bardzo skomplikowaną. Znalezienie optymalnych tras, które umożliwią przetransportowanie jak największej ilości osób w celu zmaksymalizowania zysku, przy zachowaniu możliwie najkrótszych tras, których zamysłem jest minimalizowanie kosztów poniesionych z transportem jest złożonym problemem, znanym jako jedna z odmian problemu marszrutyzacji, który jest z kolei rozwinięciem bardzo popularnego problemu komiwojażera. Problem ten polega na znalezieniu najkrótszej drogi łączącej wszystkie zdefiniowane uprzednio punkty, zaczynając i kończąc w tym samym miejscu. Problemy, do rozwiązania których potrzebne są ogromne nakłady obliczeniowe definiowane są jako problemy optymalizacyjne. W problemach takich liczba możliwych rozwiązań w przestrzeni poszukiwań z reguły jest tak duża, że niemożliwe jest przeszukiwanie wyczerpujące w celu znalezienia najlepszego z nich.

Cel pracy

Celem pracy jest dokonanie analizy porównawczej algorytmu symulowanego wyzarzania, algorytmu genetycznego oraz roju cząstek, która przeprowadzona będzie dzięki zaimplementowanej dedykowanej aplikacji bazodanowej, której przeznaczeniem jest zautomatyzowanie procesu szukania minimum globalnego zadanych dla

funkcji testowych.

Zawartość pracy

Dla osiągnięcia wyżej wymienionego celu zrealizowana została praca składająca się z sześciu rozdziałów oraz wniosków przeprowadzonych doświadczeń. W rozdziale pierwszym przedstawiony został wybór problemu optymalizacyjnego wraz z jego opisem oraz listą funkcji testowych, które użyte zostały do przeprowadzenia badań. Rozdział drugi przedstawia możliwe sposoby rozwiązania wybranego problemu optymalizacyjnego wraz z opisem użytych algorytmów metaheurystycznych. Na bazie dwóch pierwszych rozdziałów utworzony został w rozdziale trzecim projekt automatyzacji przeprowadzanych doświadczeń, na podstawie którego bazowała budowana aplikacja. Kolejny rozdział to zastosowane rozwiązania technologiczne oraz opis wykorzystanych technologii, bibliotek zewnętrznych, a także narzędzi. Na ich podstawie utworzona została architektura aplikacji bazodanowej, której specyfikacja umiejscowiona została w rozdziale piątym. Kolejny rozdział prezentuje już ściśle aspekt badawczy, który zawiera opis metod porównawczych zastosowanych algorytmów oraz wyniki doświadczeń dla użytych funkcji testowych, których analiza przeprowadzona została w rozdziale siódmym zawierającym wnioski.

1. Wybór badanego problemu optymalizacji

1.1. Opis minimalizacji funkcji ciągłych wielu zmiennych

W prezentowanej pracy dokonano porównania algorytmów metaheurystycznych odnosząc się do problemu minimalizacji funkcji wielu zmiennych. Problem ten polega na znalezieniu minimum globalnego rzeczywistej funkcji poprzez systematyczne wybieranie parametrów wejściowych z dozwolonego zakresu i obliczaniu ich wartości funkcji. Trudność problemu sprowadza się do wielkości przestrzeni przeszukiwania. Traktując problem jako czysto matematyczny, funkcja n zmiennych posiada nieskończenie wiele wartości w każdym wymiarze. Mamy więc nieskończenie wielką przestrzeń poszukiwań. Biorąc jednak pod wzgląd aspekt technologiczny i to, iż komputery bazują na danych skończonych, można w prosty sposób przedstawić skalę trudności. W czasie implementacji algorytmu, którego celem jest znalezienie minimum globalnego funkcji, należy wziąć pod uwagę dostępną dokładność obliczeniową maszyny. Zakładając, iż dokładność ta wynosi osiem miejsc po przecinku, każda zmienna, ograniczona w przedziale $[0, 100]$ może przyjąć $100 * 10^8$ różnych wartości. Już dla funkcji dwóch zmiennych, wielkość przestrzeni przeszukiwania wynosi $(100 * 10^8)^2 = 10^{20}$.

1.2. Funkcje testowe

Problem minimalizacji funkcji ciągłych bardzo dobrze nadaje się do porównania algorytmów metaheurystycznych przez wzgląd na powszechnie dostępne funkcje testowe. Funkcje te posiadają pewny specyficzny element, dzięki któremu możliwe jest porównanie wyników otrzymanych przez dany algorytm. Element ten to znajomość minimum globalnego dla danej funkcji testowej. Dzięki znajomości wartości najlepszej (najmniejszej) dla danej funkcji, wiadomo jak szybko oraz czy w ogóle badany algorytm znalazł rozwiązanie. Posiadając ten punkt odniesienia można zestawiać otrzymane rezultaty wszystkich algorytmów pod kątem czasowym lub liczby wyliczeń wartości funkcji dla ustalonych przez algorytm punktów. Do analizy wybranych zostało sześć funkcji testowych, których dobór brał pod uwagę stopień

ich skomplikowania. Funkcje te zostały wybrane z listy zawartej w (TODO: link do strony z lista funkcji) uwzględniając różną liczbę wymiarów oraz skalę ich trudności. Każda z funkcji posiada specyficzne właściwości, które zostaną wzięte pod uwagę podczas porównania rezultatów algorytmów heurystycznych.

1.2.1. Funkcja Bohachevsky'ego 1

Funkcja Bohachevsky'ego 1 jest stosunkowo prostą do minimalizacji funkcja dwóch zmiennych, której wykres przybiera kształt łuku. Z reguły jest ona badana w zakresie $x_i \in [-100, 100]$ dla $i = 1, 2$. W przedstawianej pracy magisterskiej granice to zostały jednak dwukrotnie powiększone i wynoszą $[-200, 200]$. Według doświadczeń przeprowadzonych w (TODO: link to strony z rankingiem), 81.75% doświadczeń zakończonych zostało znalezieniem minimum globalnego, które dla funkcji Bohachevsky'ego wynosi 0, dla punktu $x = (0, 0)$.

TODO: obrazek + wzór

1.2.2. Funkcja Colville'a

Jest to funkcja czterech zmiennych, która posiada jedno minimum globalne o wartości 0 dla punktu $x = (1, 1, 1, 1)$ oraz analizowana jest zazwyczaj na hipersześcianie $x_i \in [-200, 200]$ dla $i = 1, 2, 3, 4$. Według danych zawartych (TODO: link do rank) jest to funkcja trudniejsza w minimalizacji od funkcji Bohachevsky'ego, której procentowy sukces dotyczący znalezienie minimum globalnego wyniósł 72.00%.

TODO: obrazek + wzór

1.2.3. Funkcja Ackley'a

Funkcja Ackley'a jest popularną funkcją dla testów optymalizacyjnych algorytmów. W swojej dwuwymiarowej postaci, którą ukazano na obrazku (TODO: rys odnos), charakteryzuje się prawie płaskim obszarem zewnętrznym i dużym otworem w centrum. Funkcja stwarza ryzyko dla algorytmów optymalizacyjnych poprzez możliwość zatrzymania się w jednym z licznych lokalnych minimów. Istnieje możliwość rozszerzenia funkcji Ackley'a na wiele wymiarów co też uczyniono w prezentowanej pracy magisterskiej, w której rozpatrywana jest ona dla czterech zmiennych. Minimum globalne umiejscowione jest w punkcie $x = (0, 0, 0, 0)$ i jego wartość wynosi 0. Dziedzina funkcji z kolei analizowana będzie w przedziale $x_i \in [-150, 150]$ dla

$i = 1, 2, 3, 4$. Dla wspomnianych już testów, których wyniki dostępne są do wglądu w odnośniku (TODO: odn do rank), procentowy sukces znalezienia minimum globalnego wyniósł 48.25%.

TODO: obrazek + wzór

1.2.4. Funkcja Rosenbrocka

Funkcja Rosenbrocka jest to niewypukła funkcja, która jest bardzo popularna w kontekście optymalizacji jako test dla algorytmów optymalizacyjnych. Nazywana jest również przez wzgląd na swój kształt "Funkcją Bananową Rosenbrocka" albo "Doliną Rosenbrocka". Funkcja Rosenbrocka powszechnie jest stosowana w kontekście optymalizacji funkcji dwóch zmiennych. Istnieje jednak możliwość rozszerzenia jej do wielu wymiarów. W prezentowanej pracy magisterskiej rozpatrywana jest funkcja Rosenbrocka czterech zmiennych, której minimum globalne mieści się w punkcie $x = (1, 1, 1, 1)$ i wynosi 0. Ustaloną dziedziną funkcji jest $x_i \in [-200, 200]$ dla $i = 1, 2, 3, 4$. Opisywana funkcja Rosenbrocka jest funkcją trudną do minimalizacji i według wyników testów zawartych w (TODO: link do rank) procentowy sukces znalezienia minimum globalnego wyniósł tylko 8,42%.

TODO: obrazek + wzor 2 i 4zm

1.2.5. Funkcja Eggholdera

Kolejną wybraną funkcją została dwuwymiarowa funkcja Eggholdera. Jest to funkcja, której graficzna reprezentacja zawarta w rysunku (TODO: dodaj rys i alias) przypomina pasmo górskie z licznymi dolinami. Jest to funkcja trudna do optymalizacji przez wzgląd na licznie występujące minima lokalne. Dziedzina funkcji powszechnie rozpatrywana jest w przedziale $x_i \in [-512, 512]$ dla $i = 1, 2$. Minimum globalne znajduje się w punkcie $x = (512, 404.2319)$ i wynosi -959.6407 . Przez wzgląd na jego nietypowe położenie i wspomniane już liczne minima lokalne, łącznie 18.92% testów zawartych w (TODO: odnośnik do rank) zakończyło się jego znalezieniem.

1.2.6. Funkcja Griewanka

Ostatnią wybraną do testów funkcją jest funkcja Griewanka, której minimum globalne znalezione zostało w tylko 6.08% testów zawartych w (TODO: link do

rank). Jest to funkcja posiadająca bardzo dużo regularnie rozmieszczonych minimumów lokalnych które utrudniają znalezienie globalnego minimum znajdującego się w punkcie $x = (0, \dots, 0)$, dla którego wartość funkcji wynosi 0. Opisywana funkcja jest funkcją wielowymiarową, która prezentowanej pracy magisterskiej sprowadzona została do funkcji trzech zmiennych o dziedzinie $x_i \in [-200, 200]$ dla $i = 1, 2, 3$. Poniżej na rysunku (todo odnośnik rysunek) zaprezentowano opisywaną funkcję w postaci dwuwymiarowej na której można dostrzec liczne minima globalne oraz ich regularne rozmieszczenie.

2. Metody rozwiązywania wybranego problemu optymalizacji

2.1. Algorytmy dokładne

Klasycznym podejściem do znalezienia minimalnej wartości zadanej funkcji testowej jest próba porównania wartości funkcji dla wszystkich możliwych parametrów wejściowych i wybrania w ten sposób optymalnego rozwiązania. W rzeczywistości jednak takie rozwiązanie nie jest praktyczne przez wzgląd na olbrzymią możliwą liczbę takich parametrów. Jak już wspomniano w rozdziale 1.1, liczba rozwiązań dla funkcji ograniczonej już do dwóch zmiennych może wynieść 10^{20} , a w przypadku trzech zmiennych – 10^{30} . Zakładając, iż możliwe by było wyliczenie miliarda wartości funkcji na sekundę, to w godzinę wartość ta wyniosłaby $3.6 \cdot 10^{12}$, a w rok – $3.2 \cdot 10^{16}$. Prowadząc dalej obliczenia wychodzi, iż wyliczenie 10^{20} wartości funkcji trwałoby około 3125 lat. Widać więc, że liczba kombinacji jest tak duża, iż podejście to jest niemożliwe do wykonania w akceptowalnym czasie.

2.2. Metaheurystyki optymalizacyjne

Analizując podejście z rozdziału 2.1 może przyjść na myśl sposób, który polegać będzie na wyliczaniu wartości funkcji dla wyrywkowych parametrów. Skąd jednak wiadomo które punkty wybrać? Na podstawie czego bazować? W przypadku problemów, w których przez wzgląd na czas niemożliwe jest dojście do rozwiązania na ratunek przychodzą algorytmy heurystyczne, które umożliwiają skrócenie czasu obliczeń. Ceną którą trzeba jednak za to zapłacić jest możliwość otrzymania gorszego rozwiązania od rozwiązania najlepszego. Samo pojęcie heurystyki pochodzi od greckiego słowa *heuresis*, które znaczy ‘odnaleźć’. Metody heurystyczne polegają na użyciu reguł oraz faktów, które uzyskane na drodze badania danego problemu umożliwiają jego rozwiązanie lub zbliżenie się do poprawnej odpowiedzi. Podejście heurystyczne stosowane może być w sposób piętrowy, tworząc metaheurystyki. Metaheurystyka jest to ogólny algorytm do rozwiązywania problemów obliczeniowych,

który inspirację często bierze z mechanizmów biologicznych lub fizycznych. Określenie to oznacza tak zwaną heurystykę wyższego poziomu, co wynika z faktu, iż algorytmy tego typu bezpośrednio nie rozwiązują żadnego problemu, a wyłącznie podają metodę na utworzenie odpowiedniego algorytmu.

2.2.1. Metoda optymalizacji rojem cząstek

Metoda roju cząstek (PSO – Particle Swarm Optimization) jest przykładem optymalizacji z kategorii metod inteligencji stadnej. Powstała ona w wyniku inspiracji biologicznej, której źródłem był układ lotu stada ptaków tworzony w celu znalezienia pożywienia lub gniazda oraz uniknięcia drapieżników. Zastosowanie prostych zasad umożliwia ptakom zsynchronizowany oraz bezkolizyjny ruch, który daje efekt zachowania jednego organizmu. Ruch stada ptaków, czy ławicy ryb jest wypadkową działania wszystkich osobników i koncentruje się na utrzymaniu optymalnego dystansu od swoich sąsiadów, przy jednoczesnym podążaniu za liderem. Badania nad optymalizacją roju cząstek zapoczątkowano od próby graficznej symulacji zachowań takich grup. Bardzo szybko okazało się, iż stworzony matematyczny model może być również zastosowany jako metoda optymalizacyjna. W optymalizacji rojem cząstek, rozwiązania (cząstki) współpracują ze sobą w celu odnalezienia cząstki optymalnej. W czasie procesu optymalizacji następuje zmiana położenia każdej cząstki w przestrzeni rozwiązań poprzez wyznaczenie wektora prędkości. Wektor ten jest modyfikowany przy użyciu informacji o historii poszukiwań danej cząstki oraz jej cząstek sąsiednich. Metoda PSO w problemie optymalizacji funkcji wielowymiarowych dąży do otrzymania cząsteczki, która reprezentuje jak najmniejszą wartość funkcji i może być opisana dwoma równaniami:

$$v = W * v + c_1 * r_1 * (p - x) + c_2 * r_2 * (g - x) \quad (1)$$

gdzie,

v - aktualny wektor prędkości cząstki

W – parametr z zakresu $[0, 1]$, który determinuje wpływ poprzedniego położenia cząstki na jej obecną pozycję

p - najlepsze rozwiązanie dla cząstki

g – najlepsze rozwiązanie dla sąsiedztwa cząstek

r_1, r_2 – losowe liczby z zakresu $[0, 1]$

c_1, c_2 – parametry skalujące z zakresu $[0, 1]$

Nawiązując do powyższych równań, każda cząstka roju przeszukuje przestrzeń rozwiązań zmieniając położenie na podstawie swoich najlepszych rozwiązań p_i , jednocześnie wykorzystując informację o najlepszym rozwiązaniu w sąsiedztwie p_t . Parametry skalujące umożliwiają kontrolę wpływu danych części wektora prędkości na wynik. W przypadku, w którym c_1 będzie równe zero, cząstka będzie wykorzystywała tylko i wyłącznie informację o najlepszym rozwiązaniu w roju. Z kolei jeśli wartość parametru c_2 zostanie ustawiona na zero, cząstka będzie poszukiwała rozwiązania samodzielnie, bez uwzględnienia rozwiązań, które uzyskane zostały przez inne cząstki.

2.2.2. Symulowane wyżarzanie

Algorytm symulowanego wyżarzania po raz pierwszy został opisany w 1953 roku przez Nicolasa Metropolisia. Sposób działania algorytmu jak i również jego nazwa odnosi się do procesów fizycznych, które wykorzystywane są w metalurgii. Proces wyżarzania polega na rozgrzaniu ciała stałego do określonej temperatury, a następnie jego powolnym studzeniu. Konsekwencją tego działania jest zmiana struktury krystalicznej materiału, który poddany został wyżarzaniu. W czasie procesu ochładzania metali dostrzeżono, iż cząsteczki ciała wraz z jego powolnym schładzaniem tworzą bardziej regularne struktury, niż w przypadku szybszego obniżenia temperatury, kiedy to chłodzone cząsteczki nie potrafią znaleźć optymalnego położenia. Algorytm symulowanego wyżarzania jest usprawnieniem starszych metod iteracyjnych, które polegały na ciągłym ulepszaniu istniejącego rozwiązania do momentu braku możliwości jego poprawy. W metodach tych zatrzymanie algorytmu mogło nastąpić przy rozwiązaniu pseudo-optymalnym – lokalnym minimum. Nie istniała wówczas możliwość wyjścia z owego lokalnego minima i kierowania się w kierunku minimum globalnego. Bardzo ważną cechą opisywanego algorytmu jest możliwość wyboru, z pewnym prawdopodobieństwem, gorszego rozwiązania. Dzięki temu problem utknięcia w lokalnym minimum nie jest już groźny. Za wybór gorszego rozwiązania ma wpływ podstawowy parametr przeniesiony z podstaw termodynamicznych algorytmu – temperatura. Im jest ona wyższa, tym większe istnieje prawdopodobieństwo wyboru i zaakceptowania gorszego rozwiązania. W czasie działania algorytmu, temperatura obniża się i działanie algorytmu zbliża się w swoim zachowaniu do typowych metod iteracyjnych. W celu wykonania algorytmu symulowanego wyżarzania

w kontekście optymalizacji funkcji wielu zmiennych należy na początku losowo wygenerować punkt startowy, który mieści się na płaszczyźnie poszukiwań, wyliczyć dla niego wartość funkcji oraz wybrać temperaturę startową z dostępnego zakresu $[0,100]$. Każda iteracja polega na wyborze losowego rozwiązania z sąsiedztwa, wyliczenia dla niego wartości funkcji i porównaniu z obecnie najlepszym rezultatem oraz obniżeniu temperatury. W przypadku, w którym wartość funkcji nowego punktu jest mniejsza (lepsz), jest on zaklasyfikowany jako najlepszy. W przeciwnej sytuacji punkt nie jest natychmiastowo odrzucany. Algorytm akceptuje gorsze rezultaty bazując na funkcji akceptacyjnej, która prezentuje się następująco:

$$\frac{1}{1 + \exp(\frac{\Delta}{\max(T)})} \quad (2)$$

gdzie,

Δ – różnica wartości starego i nowego punktu

T – wartość temperatury

W sytuacji, w której Δ i T są wartościami dodatnimi, prawdopodobieństwo akceptacji mieści się pomiędzy 0 i $\frac{1}{2}$. Niższa temperatura prowadzi do mniejszego prawdopodobieństwa zaakceptowania gorszego rezultatu. Podobnie jest z deltą – im większa delta tym mniejsza szansa na zaakceptowanie.

2.2.3. Algorytm genetyczny

Model algorytmu genetycznego po raz pierwszy zaprezentowany został w 1975 roku przez Johna Hollanda, który w pracy „Adaptation in Natural and Artificial Systems” przedstawił fundamenty założeń dotyczących adaptacji darwinowskiej teorii ewolucji w systemach informatycznych. W opisie algorytmu genetycznego posługuje się powszechną terminologią biologiczną. Z tego też powodu mówi się, iż algorytmy genetyczne przetwarzają populację osobników, która reprezentuje rozwiązanie danego problemu. Każdy element populacji nazywany jest chromosomem, a jego składowe genami. Allele z kolei, są to możliwe stany (wartości) genu, które umiejscowione są na pozycjach zdefiniowanych jako locus. W badanych modelach komputerowych, osobniki (chromosomy) mogą być opisane jako różne struktury – zaczynając na łańcuchach binarnych, a kończąc na bardzo złożonych obiektach. W określonej iteracji zwanej zamiennie pokoleniem albo generacją, dane chromosomy na bazie określonej miary ich dostrojenia podlegają ocenie. Ocena ta skutkuje wyborem najlepiej

przystosowanych osobników, które wezmą udział w kolejnych iteracjach algorytmu. Nim jednak wybrane osobniki populacji utworzą nową generację, zostają poddane modyfikacjom spowodowanym podstawowymi operacjami genetycznymi – krzyżowaniem, selekcją oraz mutacją. W kontekście problemu optymalizacji funkcji wielu zmiennych, inicjalizacja algorytmu genetycznego polega na wygenerowaniu populacji początkowej, która złożona jest z określonej liczby chromosomów. Każdy chromosom reprezentowany w populacji posiada taką samą długość, która ustalona jest zależnie od rozwiązywanego problemu na etapie implementowania algorytmu. Przed nastąpieniem etapu generowania musi być jednak określony sposób kodowania informacji zawartej w chromosomie, która dotyczy rozwiązania. W algorytmie Hollanda nie było domyślnie zdefiniowanego sposobu kodowania chromosomów. Powszechnie uznaje się jednak, iż stosuje się kodowanie binarne. Takie też kodowanie jest zastosowane w kontekście omawianego problemu optymalizowania funkcji wielu zmiennych. Kolejnym etapem, który następuje po wygenerowaniu populacji początkowej oraz wyborze kodowania chromosomów jest wyznaczenie jakości chromosomów danej populacji. W tym celu obliczana jest wartość tak zwanej funkcji oceny, która definiuje poziom dopasowania konkretnego chromosomu. Tym sposobem można stwierdzić, które z nich lepiej rozwiązują dane zagadnienie, a które gorzej. Znalezienie rozwiązania danego problemu sprowadza się do znalezienia ekstremum wspomnianej funkcji oceny. Kolejną częścią algorytmu jest zastosowanie mechanizmu selekcji, który definiuje sposób wyboru rozwiązań rodzicielskich, z których tworzone będą tak zwane rozwiązania potomne użyte w następnej generacji. Podstawowy algorytm genetyczny w operacji selekcji stosuje metodę ruletki. Metoda ta polega na przydzieleniu każdemu chromosomowi z danej populacji prawdopodobieństwa według wzoru:

$$p_i = \frac{f_i}{\sum_{j=1}^N f_j} \quad (3)$$

gdzie, f_i - wartość funkcji oceny chromosomu i -tego p_i – prawdopodobieństwo reprodukcji

W celu wybrania puli rodzicielskiej, koło ruletki o obwodzie jeden dzielone jest na części o długości p_i , a następnie z zakresu $[0, 1]$ losowana jest liczba, która jednoznacznie identyfikuje punkt na ruletce, a co za tym idzie konkretny chromosom. Chromosom ten brany będzie pod uwagę w procesie następnej reprodukcji, a losowanie powtarzane jest tak długo, aż wylosowana zostanie ustalona liczba chro-

mosomów. W problemie minimalizacji funkcji wielu zmiennych istnieje możliwość, iż wartość funkcji oceny będzie ujemna. W celu zniwelowania problemu ujemnego prawdopodobieństwa powyższy wzór został zmodyfikowany stosując skalowanie przystosowania:

$$p_i = \frac{f_i - f_{min}}{\sum_{j=1}^N f_j - f_{min}} \quad (4)$$

gdzie f_{min} jest wartością funkcji przystosowania najgorszego chromosomu.

Po etapie selekcji pozostaje do zdefiniowania kwestia wymiany pokoleń. W implementacjach często stosowana jest metoda całkowitego zastępowania, w której cała aktualna populacja, podlega operacjom krzyżowania i mutacji. Innym sposobem jest metoda zastępowania częściowego, w której część najlepszych chromosomów obecnej populacji przechodzi do populacji potomnej bez żadnych zmian, a pozostałe elementy z kolei biorą udział w operacji krzyżowania i mutacji. Często stosowaną praktyką jest zastosowanie zastępowania elitarnego, w którym na podstawie parametru określającego wielkość elity, część najlepszych osobników jest kopiowana do nowej generacji już na samym początku. Umożliwia to zapamiętanie najlepszych chromosomów które mogły być zmienione poprzez działanie operatorów genetycznych.

Pierwszym z takich operatorów jest krzyżowanie, które jest operacją umożliwiającą tworzenie nowych rozwiązań. Jego koncept bazuje na procesie rozmnażania organizmów, w czasie trwania których dziecko dziedziczy część genów rodziców. W kontekście omawianego algorytmu genetycznego, krzyżowanie polega na przecięciu chromosomów w ustalonym punkcie i ich wzajemnego zamienienia. Drugim operatorem genetycznym jest mutacja, która umożliwia wprowadzenie nowego elementu do populacji poprzez tworzenie różnorodności. Analogicznie jak w otaczającym nas świecie, w algorytmie genetycznym, mutacje zdarzają się rzadko. Ich skala zazwyczaj zależy od parametru, który przyjmuje niskie wartości. W odniesieniu do chromosomów w postaci binarnej, mutacja może polegać na zamianie losowego genu na wartość przeciwną. Tak utworzona nowa generacja ponownie przechodzi przez wszystkie punkty algorytmu. Dzieje się tak aż do czasu, w którym spełnione zostaną warunki zatrzymania, które w kontekście przedstawianego zagadnienia opisane zostały w rozdziale 6.1 opisującym metody porównawcze wybranych algorytmów

obejmujące w swojej treści warunki stopu opisanych trzech metaheurystyków.

3. Automatyzacja przeprowadzanych badań

Porównanie algorytmów metaheurystycznych w odniesieniu do problemu minimalizacji funkcji wielu zmiennych jest zadaniem bardzo skomplikowanym przez fakt ilości doświadczeń, które trzeba wykonać. Badania porównawcze przeprowadzane będą pod kątem kilku parametrów. Dla każdego z nich należy przeprowadzić wielokrotne testy dla każdego testowanego algorytmu. Ustalając próbkę testu na poziomie 10^4 prób, z której będzie obliczana wartość średnia oraz biorąc pod uwagę dwa parametry porównawcze, z których każdy przyjmować może dla przykładu dziesięć wartości, liczba testów dla jednego algorytmu oraz jednej funkcji testowej osiąga już wartość $2 * 10^5$. Manualne przetwarzanie w środowisku Matlab przy ograniczonej funkcjonalności agregowania wyników jest bardzo czasochłonnym zadaniem. W tym celu zdecydowano się zbudować dedykowaną aplikację bazodanową, która będzie umożliwiała automatyzację przedstawianej operacji. Użytkownik z poziomu aplikacji będzie miał możliwość wyboru funkcji testowej, algorytmu metaheurystycznego oraz jego parametrów, a także liczby testów, która ma być przeprowadzona przy zadanych wartościach. Aplikacja automatycznie będzie wysyłała zapytania do środowiska obliczeniowego Matlab, obierała wyniki oraz umieszczała je w bazie danych, z której w prosty i efektywny sposób można będzie przeprowadzić ich agregację w celu przedstawienia wyników i ich porównania. W ten sposób narzut pracy, który niezbędny jest do implementacji przedstawionej aplikacji z całą pewnością się zwróci oraz umożliwi dalszą analizę algorytmów w kontekście problemu funkcji wielu zmiennych ponieważ aplikacja umożliwiać będzie również proste dodanie do niej kolejnych algorytmów funkcji testowych.

4. Wykorzystane rozwiązania technologiczne

4.1. Zastosowane technologie

Obecny rozdział obejmuje opis wykorzystanych technologii, które umożliwiły implementację aplikacji. Opis ten dotyczy języka programowania, w którym napisany został backend(TODO: dodać przypis) aplikacji oraz silnika graficznego aplikacji wraz z językiem zapytań bazy danych.

4.1.1. .NET Framework/C#

.NET Framework jest to platforma programistyczna wydana przez firmę Microsoft w 2002 roku. Przeznaczona jest ona do wytwarzania oprogramowania przeznaczonego dla systemów operacyjnych z rodziny Windows. Główną składową przedstawianej platformy są kompilatory języków wysokiego poziomu, które umożliwiają przeprowadzenie operacji kompilacji programów napisanych w językach Visual Basic, F#, C++/CLI. Platforma .NET wspiera również jeden z najpopularniejszych języków programowania na świecie - C#, w którym napisana została aplikacja odnosząca się do prezentowanej pracy magisterskiej. Według rankingu TIOBE Software z grudnia 2015 roku, język C# uplasowany jest na piątym miejscu, spośród pięćdziesięciu najpopularniejszych języków, które zostały wzięte pod uwagę. C# jest to nowoczesny, zorientowany obiektowo język programowania stworzony przez firmę Microsoft. Jego pierwsza wersja wydana została już w połowie 2000 roku, przy dużej zasłudze głównego projektanta języka - duńskiego inżyniera oprogramowania Andersa Hejlsberga. Język ten może zostać użyty w celu pisania aplikacji webowych, desktopowych oraz przeznaczonych na urządzenia przenośne. Programy w nim napisane, kompilowane są do pośredniego kodu, który zapisany jest w CIL (ang. Common Intermediate Language) i wykonany w środowisku uruchomieniowym .NET Frameworka. Poziom trudności nauki C# uznawany jest za stosunkowo niski, głównie z powodu posiadania licznych udogodnień oraz modułów, które upraszczają pracę programistyczną. Do elementów tych można zaliczyć brak konieczności dodawania plików nagłówkowych, które niezbędne były w języku C++, automatyczne zwalnianie dynamicznie przydzielonej pamięci za które odpowiedzialny jest Garbage

Collection, inicjalizowanie zmiennych ich domyślnymi wartościami oraz wprowadzenie dodatkowych elementów składowych klas, takich jak indeksery oraz właściwości (ang. properties).

4.1.2. WPF / XAML

Windows Presentation Foundation (WPF) jest to silnik graficzny, który wprowadzony został wraz z trzecią wersją środowiska .NET. Okna w aplikacjach zaimplementowanych w WPF wyświetlane są za pomocą grafiki wektorowej, która to wspomagana jest przez akceleratory grafiki 3D. API w technologii WPF opiera się na języku XML, a konkretniej jego odmianie - XAML. Extensible Application Markup Language (XAML) jest to deklaratywny język znaczników, którego przeznaczeniem jest opis interfejsu użytkownika implementowanego w WPF. Pozwala on zaprojektowanie oraz rozmieszczenie wszelakich elementów wizualnych oraz umożliwia zrównoleglenie pracy programistów pracujących nad logiką biznesową budowanej aplikacji oraz grafików, którzy odpowiedzialni są za stworzenie graficznego interfejsu użytkownika. Zdarza się, iż graficy przez wzgląd na zakres swoich obowiązków nie znają żadnego języka programowania. Problem ten zniwelowany dzięki językowi XAML, który pozwala na zrozumienie przez osoby nietechniczne zasady działania oraz powiązań poszczególnych okien, a także umożliwia projektowanie GUI w prosty sposób z poziomu drzewiastej struktury lub dedykowanego programu graficznego Expression Blend. Aplikacja ta umożliwia przeprowadzenie wszelkich operacji z poziomu graficznego środowiska.

4.1.3. TSQL

Transaction-SQL (T-SQL) jest to rozwinięcie standardowego języka SQL, który to utworzony został w latach siedemdziesiątych specjalnie na potrzeby relacyjnych baz danych przez firmę IBM. T-SQL pozwala na tworzenie konstrukcji takich jak instrukcje warunkowe i pętle oraz umożliwia stosowanie zmiennych. Aktualnie stosowany on jest do tworzenia zapytań bazodanowych przez firmy, które potrzebują bardziej zaawansowanych struktur niż tych, które dostępne są w SQL. T-SQL wprowadził możliwość stosowania bazodanowych wyzwalaczy, procedur oraz funkcji składowanych, które to przy rozbudowanej strukturze tabel ułatwiają i zwiększają efektywność podczas pracy z bazą danych.

4.2. Zastosowane narzędzia

W celu efektywnej pracy z technologiami, które opisane zostały w rozdziale 4.1 warto użyć dedykowanych narzędzi, które ułatwiają zastosowanie funkcjonalności wspomnianych technologii. W tym celu w trakcie pracy nad prezentowanymi projektami magisterskimi, użytych zostało kilka narzędzi, które pozwoliły skrócić czas potrzebny na implementację aplikacji, przeprowadzenie badań oraz zagregowanie ich rezultatów.

4.2.1. Matlab

Matlab jest to środowisko przeznaczone do wykonywania obliczeń numerycznych, matematycznych oraz symulacyjnych. Początkowo Nazwa środowiska odnosi się do słów MATrix LABoratory, gdyż Matlab przeznaczony był początkowo do numerycznych obliczeń macierzowych. Aktualnie aplikacja ta ma zdecydowanie szersze możliwości - posiada wiele funkcji bibliotecznych, umożliwia ich rozbudowę, a także definiowanie nowych przez użytkownika. Matlab posiada również dedykowany język programowania, czego konsekwencją jest możliwość pisania w pełni funkcjonalnych aplikacji pracujących w opisywanym środowisku. W aspekcie grafiki, Matlab pozwala na rysowanie dwu oraz trójwymiarowych wykresów, a także wizualizację rezultatu obliczeń w postaci animacji. Istotną kwestią w kontekście prezentowanej pracy magisterskiej jest posiadanie przez środowisko Matlab terminala, który pozwala na wprowadzanie komend i wykonywanie funkcji. Istnieje możliwość jego samodzielnego uruchomienia oraz połączenia z innymi systemami za pośrednictwem dedykowanych bibliotek, które umożliwiają synchronizację Matlab z aplikacjami napisanymi w technologii .NET, Java czy C++.

4.2.2. SQL Server Management Studio 17

W czasie pracy nad aplikacją automatyzującą proces przeprowadzania testów wykorzystano darmowe narzędzie, którego przeznaczeniem jest zarządzanie bazą danych - SQL Server Management Studio 17. Potrzeba użycia narzędzia wynikła z istniejącej infrastruktury aplikacji, która opiera się na rozwiązaniach Microsoftu. Zastosowane narzędzie znacznie ułatwiło pracę i wspomogło proces projektowania bazy danych dzięki funkcjonalności generowania diagramów, które umożliwiły podgląd struktury bazy oraz relacji pomiędzy poszczególnymi tabelami. Kolejną olbrzymią

zaletą SQL Management Studio jest możliwość tworzenia zapytań bazodanowych, które pozwalają w bardzo elastyczny sposób pogrupować olbrzymie ilości danych w wybrany przez użytkownika sposób. Umożliwia to w krótkim czasie stworzenie statystyk zastosowanych algorytmów, które dynamicznie będą się aktualizowały wraz z napływem kolejnych danych do bazy.

4.2.3. Visual Studio 2015

Visual Studio jest to bardzo rozbudowane środowisko deweloperskie firmy Microsoft. Stosowane jest do procesu wytwarzania oprogramowania z graficznym interfejsem użytkownika w technologii WPF, WinForms, Web Sites oraz Xamarin. Visual Studio posiada zaawansowany edytor kodu, który wspiera mechanizm podpowiadania składni kodu - IntelliSense, który może być dodatkowo rozbudowany poprzez dedykowane narzędzia np. Resharper. Zintegrowany debugger zawarty w środowisku Visual Studio umożliwia również analizę programu w czasie jego działania, co w bardzo łatwy sposób umożliwia odnalezienie potencjalnych błędów oraz sprawdzenie poprawności zaimplementowanego rozwiązania. Funkcje te wraz z wbudowanym designerem do tworzenia aplikacji WPF oraz narzędziem do projektowania baz danych umożliwiły skoncentrowanie pracy programistycznej przy jednym narzędziu, dzięki czemu możliwa była znaczna oszczędność czasowa w temacie poszukiwań niezbędnych narzędzi i ich integracji. Visual Studio, SQL Server Management Studio 17 oraz zastosowane technologie są wytwarzane przez jedną firmę - Microsoft. Dzięki temu aspektowi ich połączenie i synchronizacja jest bezproblemowa i bardzo szybka.

4.2.4. Resharper

Wydajność pracy w temacie projektów programistycznych jest priorytetem, który bezpośrednio przekłada się na oszczędność czasową, a co za tym idzie na korzyści finansowe. Dostępne są narzędzia, których przeznaczeniem jest poprawienie efektywności osoby implementującej aplikację poprzez kontrolę pisanego kodu według zdefiniowanych uprzednio zasad oraz zautomatyzowanie często powtarzanych czynności. Resharper jest to dodatek do środowiska Visual Studio, który w znacznym stopniu rozbudowuje dostępne jego funkcjonalności, ułatwiając przy tym refaktoryzację oraz pisanie kodu. Funkcje, które zastosowane być mogą z poziomu Resharpera można pogrupować na kilkanaście grup, z których jedną z najważniejszych jest moduł, który zajmuje się inspekcją kodu. W trakcie pisania kodu z uruchomionym w

tle Resharperem następuje sprawdzanie w czasie rzeczywistym ponad 2000 zasad, które dotyczą jego poprawności i w sytuacji znalezienia niespójności, następuje poinformowanie programisty na poziomie interfejsu Visual Studio o zaistniałym błędzie wraz z jego szczegółowym opisem i miejscem wystąpienia. Niespójności te mogą dotyczyć dla przykładu możliwości zastąpienia części kodu jego wydajniejszą wersją, ostrzeżeniem programisty przed fragmentem kodu, który potencjalnie może spowodować błędne działanie całej aplikacji oraz fragmentami martwego kodu. Kolejną bardzo ważną grupą funkcji jest funkcjonalność generowania kodu. W czasie pracy implementacyjnej sporo czynności takich jak edycja nazw czy pisanie nowych klas oraz metod notorycznie się powtarza. Za pomocą skrótów klawiaturowych, wszystkie powyższe akcje Resharper wykona za programistę. Wygeneruje on niezbędne przydziedziczeniu interfejsu wszystkie jego składowe, przeniesie daną klasę do odrębnego pliku oraz automatycznie dokona zamiany wybranej nazwy na inną w obrębie całej solucji. Zaprezentowane funkcje Resharpera wraz z innymi, które dostępne są do wglądu w odnośniku (TODO: dodać odnośnik), umożliwiły zmniejszenie czasu potrzebnego na implementację niezbędnych w projekcie modułów poprzez zminimalizowanie liczby pojawiających się zagrożeń we wczesnej fazie implementacji oraz zautomatyzowanie powtarzalnych czynności.

4.3. Wykorzystane biblioteki zewnętrzne

W trakcie budowy systemu informatycznego zdarzają się sytuacje, w których korzysta się z aplikacji różnych firm, które domyślnie nie umożliwiają ich połączenia. Problem taki wystąpił również w czasie pracy nad prezentowanym projektem magisterskim. Użycie narzędzia innej firmy niż Microsoft, jakim jest Matlab doprowadziło do konieczności znalezienia metody jego połączenia ze środowiskiem .NET

4.3.1. Matlab Application Type Library v.1.0

Matlab Application Type Library w wersji pierwszej jest to otwarta biblioteka przeznaczona dla środowiska .NET posiadająca API umożliwiające wykonywanie operacji Matlabowych stosując składnię C#. Biblioteka ta umożliwia odwoływanie się do uprzednio zdefiniowanych w Matlabie funkcji, dostarczając odpowiednich parametrów oraz odbiera wyniki obliczeń, które mogą być dalej przetwarzane bez konieczności manualnego kopiowania danych z aplikacji Matlab. Biblioteka posiada

bardzo ogólnie zdefiniowane metody, do prawidłowego wykonania których niezbędna jest szczegółowa wiedza, która ograniczona jest jednak przez wzgląd na brak dokumentacji. Przy dłuższej pracy jest jednak możliwe dojście do sposobu skorzystania z zaawansowanych funkcji które dostarcza środowisko Matlab. W rozdziale 5.4 przedstawiono dokładny sposób przekazywania i odbierania danych pomiędzy środowiskiem Matlab oraz .NET.

5. Architektura budowanej aplikacji

Budowanie bazodanowej aplikacji komputerowej łączącej się z systemem trzecim wymaga szczegółowej analizy wszystkich elementów, które mają odniesienie do jej architektury. Przez konieczność budowy dwóch oddzielnych elementów - bazy danych oraz aplikacji desktopowej, analiza ta podzielona została na część odwołującą się do architektury aplikacji, modelowania bazy danych oraz komunikacji bazy danych z projektem programistycznym oraz komunikacji środowiska Matlab z implementowaną aplikacją.

5.1. Architektura aplikacji

W aspekcie programowania, podobnie jak w innych dziedzinach, w których przeprowadzana jest operacja budowy zadanego elementu, należy dokładnie zaplanować jego proces. W przedstawianym rozdziale przedstawiony został opis metodologii, która pozwala na uporządkowanie procesu budowania aplikacji komputerowej wraz z jej odmianą, która zastosowana została podczas pracy nad niniejszą pracą magisterską. W rozdziale 5.1.3 został również zawarty szczegółowy opis poszczególnych elementów ze strony projektu programistycznego, który to jest efektem pracy implementacyjnej.

5.1.1. Wzorce architektoniczne oprogramowania

Bardzo dobrą praktyką programistyczną jest przeprowadzenie procesu budowy aplikacji w taki sposób, aby możliwy był efektywny jej rozwój oraz dokonanie w łatwy sposób zmian w istniejących już funkcjonalnościach. W tym celu budowę aplikacji należy przeprowadzać zgodnie z ustalonymi etapami produkcji oprogramowania. Etapy te definiują obowiązek ustalenia wymagań budowanego systemu oraz określenia jego ogólnej architektury. Część dotycząca określenia architektury jest niezwykle ważna ponieważ jej zmiana podczas fazy implementacji jest niezwykle problematyczna i w wielu przypadkach wręcz niemożliwa bez konieczności powtórzenia pracy od początku. Kolejne etapy mają na celu zrealizowanie zdefiniowanej

wcześniej architektury poprzez zaprogramowanie każdego komponentu oprogramowania wraz ze wszystkim niezbędnymi wzajemnymi połączeniami, przetestowanie całości zaimplementowanego systemu, a także jego uruchomienie oraz zniwelowanie błędów, które pojawiły się w trakcie jego działania. W kontekście planowania i budowania architektury systemu bardzo użyteczne są wzorce architektoniczne, które to są powszechnymi, sprawdzonymi oraz ogólnie przyjętymi sposobami rozwiązania określonego problemu z zakresu architektury oprogramowania. Definiują one ogólną strukturę systemu informatycznego, elementy, które wchodzi w jego skład oraz zasadę komunikowania się komponentów pomiędzy sobą. Dokonanie wyboru odpowiedniego wzorca jest w dużym stopniu zależne od technologii, która stosowana jest w projekcie. W przypadku prezentowanej aplikacji oraz technologii WPF na której bazuje, stosowanym powszechnie wzorcem jest Model View ViewModel (MVVM), który to jest odmianą ogólnego wzorca MVC.

5.1.2. Zastosowany wzorec architektoniczny – MVVM

MVVM to wzorec, który dzięki separacji warstwy logiki biznesowej oraz warstwy prezentacji, pozwala na tworzenie łatwo testowalnej aplikacji, której fragmenty kodu mogą być ponownie użyte w innych projektach programistycznych. Aplikacje pisane w technologii WPF przy użyciu wzorca MVVM umożliwiają również ich prostą rozbudowę, a poprzez obowiązek zachowania odpowiedniej struktury kodu, którą owy wzorec wymusza, zrozumienie kodu przez nową osobę jest o wiele prostsze i mniej czasochłonne niż w przypadkach aplikacji pisanych bez żadnej ogólnej struktury. MVVM jest to wzorec, który jest bardzo popularny w gronie programistów skoncentrowanych przy technologii WPF. Powodem tego jest możliwość użycia największych zalet tej technologii, takich jak binding (wiązania), behavior (zachowania) oraz command (komendy). Struktura kodu aplikacji bazującej na opisywanym wzorcu, podzielona jest na trzy oddzielne warstwy, których nazwy składają się na nazwę wzorca: Model, Widok (View) oraz Model Widoku (ViewModel). Każda z warstw spełnia w aplikacji specjalnie określone funkcje i przetwarza dedykowane dla siebie dane. Graficzna prezentacja oraz kierunki przesyłania danych dostępna jest do względu na rysunku (TODO: dodać numer rysunku). Warstwa Modelu we wzorcu MVVM jest odpowiedzialna za tak zwaną logikę biznesową budowanego systemu. W aplikacji budowanej na potrzeby prezentowanej pracy magisterskiej, warstwa ta zawiera wszystkie klasy, które stworzone zostały za pomocą narzędzia mapowa-

nia obiektowo-relacyjnego Entity Framework w celu odwzorowania relacyjnej bazy danych na poziom obiektów dostępnych w kodzie. Każda klasa zawarta w części modelu, której dane mają zostać wysłane do warstwy widoku w celu ich wyświetlenia użytkownikowi zobligowane są do implementacji interfejsu *INotifyPropertyChanged*, który aktywnie współpracuje z wiązaniem stosowanym w WPF. Drugą z kolei warstwą jest warstwa widoku, której odpowiedzialność sprowadza się wyłącznie do wyświetlania danych. Jej rolą jest prezentowanie danych w oknie aplikacji, do którego dostęp mają użytkownicy systemu. Ostatnią warstwą modelu MVVM jest warstwa ViewModelu, której przeznaczeniem jest pośredniczenie w wymianie danych pomiędzy modelem oraz widokiem, do którego nie posiada jednak żadnej referencji. Elementy widoku odnoszą się do ViewModelu dzięki wspomnianym już komendom oraz bindingowi. Taki mechanizm zapewnia w pełni separację warstwy ViewModelu, a co za tym idzie, umożliwia pełne jego przetestowanie bez żadnej zależności od rzeczywistej warstwy widoku oraz modelu.

5.1.3. Model aplikacji

Użycie wzorca MVVM w aplikacji implementowanej na potrzeby prezentowanej pracy magisterskiej poskutkowało w projekcie programistycznym do powstania obszernej solucji, która składa się z ponad siedemdziesięciu plików. Dzięki zaplanowanej strukturze podziału elementów na foldery, zachowano porządek, który umożliwia szybkie oraz intuicyjne wyszukiwanie potrzebnych składowych aplikacji. Wszelkie pliki klas zostały umiejscowione w katalogach nazwanych w sposób adekwatny do ich przeznaczenia, przez co odnalezienie przez programistę szukanego elementu nie przysparza żadnych problemów.

Managers

Managers jest to katalog zawierający klasę menadżera tworzącego i wysyłającego żądanie przeprowadzenia doświadczenia do środowiska Matlab. Menadżer ten za pośrednictwem klas dopasowujących tworzy żądanie zgodne ze standardem zastosowanej biblioteki opisanej w 4.3.1, wysyła je do środowiska obliczeniowego oraz odbiera rezultaty.

Matlab

Folder *Matlab* ukazany na rysunku (TODO: dodaj rysunek) zawiera pliki funkcji zapisanych w środowisku Matlab. Pliki te zawierają definicję trzech algorytmów metaheurystycznych oraz wybranych funkcji testowych. Przez fakt na ograniczoną funkcjonalność zastosowanego API, łączącego środowisko .NET ze środowiskiem Matlab, definicje funkcji testowych oraz algorytmów musiały znaleźć się w jednym katalogu z powodu braku wsparcia przechodzenia pomiędzy różnymi katalogami.

Model

Katalog Modelu przedstawiony na obrazu (TODO: dodać odnośnik) zawiera utworzoną przez Entity Framework strukturę obiektową relacyjnej bazy danych. Liczba plików, które zawiera uzależniona jest bezpośrednio od liczby tabel, która zastosowana została w bazie danych. W czasie działań implementacyjnych nie jest konieczna wiedza o dokładnej strukturze przedstawianego folderu, a tylko która bazodanowa tabela zawiera jakie dane.

Services

Katalog *Servies* zawiera dwa serwisy stosowane w prezentowanej aplikacji. Pierwszym z nich jest serwis bazy danych który umożliwia połączenie się z fizycznie istniejącą bazą danych. Za pomocą dedykowanych obiektów Entity Frameworka umożliwia on zapisywanie do bazy danych rezultatów przeprowadzonych doświadczeń oraz pobieranie niezbędnych danych dotyczących stosowanych algorytmów oraz funkcji testowych. Drugim z kolei serwisem jest serwis Matlaba, który przechowuje obiekty umożliwiające dwukierunkową komunikację ze środowiskiem obliczeniowym.

Tools

Katalog narzędzi, którego graficzna reprezentacja dostępna jest do zobaczenia na rysunku (TODO: dodaj alias rysunku) jest najbardziej rozbudowanym katalogiem w drzewie solucji. Przez wzgląd na jego szerokie zastosowanie posiada on trzy podfoldery, które uściślają definicję elementów w nich się znajdujących. Pierwszym z nich jest *Parser*, który zawiera tłumacza rezultatów otrzymanych ze środowiska obliczeniowego. Przez wzgląd na nieuporządkowaną formę danych otrzymywanych z Matlaba pojawiła się konieczność ich uporządkowania, biorąc jednocześnie pod

względ, iż rezultaty doświadczeń dla różnych algorytmów oraz różnych funkcji testowych mogą posiadać inne struktury. Drugi podkatalog to *Utils*, który zawiera dwie bardzo ważne metody dopasowujące nazwy Matlabowych plików na podstawie wybranego algorytmu metaheurystycznego oraz funkcji testowej. Ostatnim podkatalogiem jest *MatlabContextWrapper*, który zawiera metody ułatwiające odwołanie się do obiektów komunikacyjnych, które pośredniczą w dwukierunkowym przekazywaniu informacji pomiędzy środowiskami .NET oraz Matlab.

View

Katalog widoku jest katalogiem najważniejszym ze strony użytkownika ponieważ zawiera definicję budowy głównego okna aplikacji oraz umiejscowienia wszystkich kontrolek jakie ono zawiera. W tym właśnie miejscu wykorzystywany jest opisany w rozdziale 4.1.2 język XAML, który pozwala na przeprowadzenie operacji wiązań oraz stosowanie komend.

ViewModel

Ostatni opisywany katalog - *ViewModel* - zawiera pliki dostosowane do pracy ze wzorcem MVVM. Odpowiadają one na interakcję użytkownika oraz realizują akcje dostępne z poziomu okna aplikacji, w którym pracuje użytkownik. Ważnym elementem ze strony programistycznej jest plik *ViewModelLocator*, w którym przeprowadzana jest operacja rejestrowania wszelkich typów zastosowanych w aplikacji. Dzięki temu, możliwe jest skorzystanie ze wzorca wstrzykiwania zależności, który pozwala na pisanie kodu o luźniejszych powiązaniach, prostszego w testowaniu oraz modyfikacji. (TODO: dodaj odnośnik do di)

5.2. Architektura bazy danych

Tematyka projektu dotycząca analizy porównawczej algorytmów metaheurystycznych doprowadziła do powstania potrzeby zastosowania środowiska bazodanowego, które umożliwia przechowywanie oraz agregowanie wyników zautomatyzowanych doświadczeń. W prezentowanym rozdziale opisany został serwer bazodanowy, który przechowuje instancję bazy, jego działanie oraz model utworzonej bazy danych.

5.2.1. Microsoft SQL Server – użyty system zarządzania bazą danych

Zastosowanie w projekcie bazy danych wymusiło obowiązek utworzenia oraz uruchomienia serwera bazodanowego. Przez fakt na zastosowane technologie, których opis znajduje się w rozdziale 4.1, użyty został Microsoft SQL Server. Jest to relacyjny system zarządzania bazą danych, którego podstawową funkcją jest przechowywanie i przetwarzanie danych na żądanie innych aplikacji, które mogą działać na tym samym komputerze lub na innym komputerze w sieci LAN czy też WAN. Przydatnym narzędziem przy pracy z Microsoft SQL Serverem jest dedykowane narzędzie z graficznym interfejsem użytkownika, który w znacznym stopniu upraszcza korzystanie z funkcji SQL serwera. W przypadku budowanej aplikacji serwer bazodanowy został utworzony na maszynie lokalnej, na której działa również aplikacja automatyzująca testy. Na potrzeby przeprowadzanych doświadczeń rozwiązanie to jest wystarczające przez fakt braku konieczności posiadania bardzo szybkiego środowiska, które wymaga uiszczenia opłat adekwatnych do rodzaju wykupywanego serwera.

5.2.2. Budowa bazy danych użytej w projekcie

Przed rozpoczęciem etapu implementacyjnego oraz po zakończeniu analizy dotyczącej wyboru wzorca architektonicznego aplikacji, zaprojektowana została struktura tabel bazodanowych wraz ze ich wszystkimi dostępnymi kolumnami oraz typami, a także połączenia i relacje między nimi. Proces projektowania bazy danych jest procesem bardzo ważnym, a jednocześnie często bagatelizowanym. W sytuacji nieprzemyślanego zaprojektowania bazy danych istnieje możliwość pojawienia się problemu z rozwojem i dodawaniem kolejnych potrzebnych tabel, na których miałyby operować nowe funkcjonalności aplikacji. Nieprzemyślana struktura tabel może doprowadzić do zbędnego powielania danych, której konsekwencją będzie bardzo szybko powiększający się rozmiar bazy danych. Kolejnym efektem źle zaprojektowanej bazy może być spowolniona praca i długie wykonywanie zapytań. W celu uniknięcia przedstawionych problemów, dokonana została szczegółowa analiza wymaganych funkcjonalności oraz danych, które one zwracają. Wykorzystana w budowanej aplikacji baza danych może zostać podzielona na dwa główne składniki - część słownikową zawierającą opisy wybranych algorytmów metaheurystycznych oraz funkcji testowych, a także część dotyczącą przeprowadzanych badań oraz wyników przez nie otrzymanych.

Część słownikowa

Na słownikową część bazy danych składają się trzy tabele, które zawierają dane wejściowe niezbędne w aplikacji: *Alghoritm*, *TestFunction* oraz *ExitFlag*.

Tabela *Alghoritm* (TODO sprawdzić poprawność nazwy) jest prostą tabelą słownikową zawierającą identyfikator oraz nazwę algorytmu metaheurystycznego. Lista algorytmów dostępnych do przetestowania w aplikacji znajduje się właśnie w tej tabeli. Na podstawie nazwy algorytmu, dopasowywana jest jej funkcja Matlabowa, w której tkwi główna logika algorytmu. W celu dodania kolejnego algorytmu, należy dodać wpis w opisywanej tabeli oraz według odpowiedniego schematu dostępnego do wglądu w klasie *FunctionNameMatcher* stworzyć funkcję w aplikacji Matlab. Tak utworzony schemat algorytmu należy kolejno dodać do warstwy ViewModelu oraz dostosować logikę okna użytkownika do wymaganych przez algorytm parametrów.

TestFunction (TODO sprawdzić poprawność nazwy) jest to tabela, która opisuje funkcje testowe na bazie których dokonywane są testy algorytmów. Zawarte w niej są takie informacje jak identyfikator funkcji, jej nazwa, poziom trudności ustalony na bazie stopnia skomplikowania funkcji testowej zaczerpnięty ze (TODO: źródło do listy algorytmów), odnośnik do wykresu danej funkcji wraz z informacjami na jej temat, zakres płaszczyzny w obrębie której ma być poszukiwana wartość minimalna oraz wymiar funkcji czyli liczba zmiennych, z której owa funkcja się składa. W celu dodania do aplikacji kolejnej funkcji testowej należy tylko dodać jej definicję w opisywanej tabeli oraz utworzyć plik Matlabowy zawierający jej wzór. Nazwa pliku powinna zgadzać się ze schematem zawartym w klasie dopasowującej - *FunctionNameMatcher*. Tak utworzony algorytm automatycznie będzie dostępny do wyboru z poziomu aplikacji.

Ostatnia tabela z części słownikowej bazy danych to tabela *ExitFlag* w której zdefiniowane są numery flag wyjścia z Matlabowych funkcji oraz ich opis. Przeznaczeniem jej jest uzyskanie informacji dotyczącej powodu zakończenia pracy danego algorytmu. Powodem tym może być dla przykładu osiągnięcie maksymalnego założonego czasu działania algorytmu, liczby iteracji lub liczby odwołań do funkcji testowej.

Część dotycząca przeprowadzonych badań

Część bazy danych odnosząca się do przeprowadzanych badań jest częścią bardziej rozbudowaną niż część słownikowa. Zawiera ona wszelkie informacje dotyczące parametrów wejściowych danego testu oraz rezultaty przeprowadzanych badań. Główną tabelą, która jest swojego rodzaju trzonem bazy danych jest tabela *Results* (TODO: sprawdź nazwę). Po przeprowadzeniu pojedynczego doświadczenia w tabeli tej tworzony jest wpis, który zawiera identyfikatory wierszy odnoszące się do pozostałych tabel, które umożliwiają uzyskanie wszelkich informacji o doświadczeniu.

W tabeli *InputParameters* (TODO: sprawdź nazwę) zawarte są informacje o parametrach wejściowych algorytmów takich jak maksymalny czas działania algorytmu, maksymalna liczba iteracji, dopuszczalna liczba odwołań do funkcji testowej oraz w zależności od wybranego algorytmu wielkość roju lub wielkość populacji.

Rezultaty przeprowadzonego badania umiejscawiane są w tabeli *ResultDetail* (TODO: sprawdź nazwę), w której to można uzyskać informacje na temat liczby przeprowadzonych iteracji, liczby odwołań do funkcji testowej, najmniejszej znalezionej wartości funkcji, czasu działania algorytmu oraz informację o powodzeniu jego wykonania. Dodatkowym elementem, który przechowywany jest w bazie jest lokalizacja punktu posiadającego najmniejszą znaną wartość funkcji. Początkowo temat pracy magisterskiej zakładał porównanie algorytmów metaheurystycznych bazując wyłącznie na funkcjach dwóch zmiennych. Lokalizacja najlepszego punktu przechowywana była w dwóch kolumnach tabeli *ResultDetails*. Po zmianie wymagań, które dotyczyły konieczności obsłużenia funkcji wielu zmiennych musiała nastąpić modyfikacja struktury bazy danych. Wartym wspomnienia są tutaj fazy dokładnej analizy potrzeb, które baza danych ma spełniać oraz proces jej projektowania. Już na tym etapie jako jedno z ryzyk projektowych założone zostało właśnie zmienienie podejścia do liczby wymiarów funkcji testowych. W celu zapewnienia prawidłowego przetwarzania i przechowywania danych została w tym celu stworzona nowa tabela - *Points*. Tabela ta jest w relacji wiele do jednego z tabelą *ResultDetails* oraz umożliwia przechowywanie wartości punktu dla każdego wymiaru jako oddzielny wpis. Dla przykładu lokalizacja punktu dla funkcji pięciu zmiennych przechowywana będzie w postaci pięciu wpisów w omawianej tabeli, z których każdy opisywać będzie jego lokalizację oraz numer wymiaru do którego ma odniesienie.

5.3. Komunikacja bazy danych z projektem programistycznym

Umożliwienie kontaktu aplikacji z bazą daną jest kluczową kwestią, która odnosi się do prawidłowego działania bazodanowego projektu programistycznego. Bezpieczne, stabilne oraz ciągle połączenie umożliwia pozbawione problemów przesyłanie danych z gwarancją ich niezmienności oraz odpowiednią informacją w momencie pojawienia się błędu komunikacyjnego. W technologii .NET, w której implementowana jest aplikacja bazodanowa możliwe jest kilka podejść do omawianego zagadnienia. Jednym z nich jest standardowe podejście udostępniane przez ADO.NET oraz nowsze, które dotyczy komunikacji na poziomie obiektów.

5.3.1. Mapowanie obiektowo-relacyjne

Mapowanie obiektowo-relacyjne (ang. ORM - Object-Relational Mapping) jest to pojęcie, które dotyczy informatycznego terminu odnoszącego się do współpracy z bazą danych przy wykorzystaniu programowania obiektowego. Dokładniej chodzi tutaj o translację danych, które przechowywane są w tabelach bazodanowych w relacyjnej bazie danych na postać obiektową, która dostępna jest z poziomu projektu programistycznego. Przedstawiony sposób komunikacji jest sposobem bardzo użytecznym przez wzgląd na brak konieczności analizy struktury bazy danych przez programistę oraz umożliwienie pobierania oraz zapisu danych z poziomu kodu, unikając bazodanowego języka zapytań SQL. Aplikacje komputerowe, które używane są przez wielu użytkowników oraz wymagają pobierania i zapisywania dużych ilości danych często korzystają z serwerów bazodanowych. Serwery te pozwalają na przechowywanie danych bez żadnych przerw oraz ich szybkie wyszukiwanie, dodawanie oraz edycję. Aspekt ten jest bardzo trudny do osiągnięcia korzystając wyłącznie ze standardowych aplikacji. W technologii .NET, standardowa komunikacja z bazą danych przebiega za pomocą protokołu ADO.NET. Przy jego zastosowaniu, w celu pobrania danych, programista musi za każdym razem połączyć się z bazą danych, manualnie zapisać zapytanie SQL, odebrać wynik, zapisać go w zmiennej oraz zamknąć połączenie. Schemat ten bardzo komplikuje kwestię utrzymania aplikacji w sytuacji modyfikacji struktury bazy danych. Zapisane przez programistę zapytanie SQL nie jest w ogóle walidowane pod kątem poprawności jego formy, a w sytuacji edycji kolumny bazodanowej, następuje obowiązek uaktualnienia wszystkich zapytań, które jej dotyczyły. Przykładowy schemat pracy podczas korzystania

z ADO.NET wraz z porównaniem analogicznej operacji w technologii ORM zaprezentowane zostało na poziomie kodu źródłowego (TODO: dodać numer)

tututu

W implementowanej aplikacji dotyczącej prezentowanej pracy magisterskiej, zdecydowano się przeciwdziałać opisanym problemom, stosując framework, który w znacznym stopniu ułatwia programiście zastosowanie wszystkich operacji na poziomie komunikacji z bazą danych.

5.3.2. Zastosowane narzędzie ORM – Entity Framework

Entity Framework jest to dedykowane dla platformy .NET narzędzie mapowania obiektowo-relacyjnego, którego zadaniem jest wspieranie budowy trójwarstwowych aplikacji bazodanowych. Budowa obiektowego modelu bazy danych w opisywanym narzędziu może być wykonana na trzy sposoby.

Pierwszą metodą jest podejście *Database First*, które jest użyteczne w sytuacji, w której dostępna jest działająca fizycznie baza danych. Korzystając z dostępnego w frameworku kreatora, istnieje możliwość określenia lokalizacji bazy oraz poddania jej automatycznemu mapowaniu, w wyniku którego wygenerowane zostają niezbędne klasy obiektowego modelu bazy danych.

Kolejnym sposobem jest *Code First*, który pozwala na utworzenie fizycznego modelu bazy danych na podstawie klas napisanych w języku C# oraz ich odpowiednimi przypisami.

Ostatnią metodą jest *Model First*, które polega na utworzeniu fizycznego modelu bazy danych posługując się wbudowanym w Entity Framework Designerem, który w dużym stopniu upraszcza tworzenie właściwości oraz encji bazodanowych. Ścieżka ta stosowana jest, gdy posiadany jest wyłącznie sam schemat bazy danych. Ze zbudowanego modelu następuje wygenerowanie fizycznego modelu bazy danych jak i również klas, które reprezentują model obiektowy. Sposób ten został zastosowany w prezentowanej pracy magisterskiej. Po analizie wymagań i utworzeniu schematu bazy danych, został on przeniesiony na poziom Designera opisywanego frameworka, który automatycznie stworzył skrypt napisany w języku SQL po wykonaniu którego utworzony został fizyczny model bazy danych, a także wygenerował wszystkie niezbędne klasy reprezentujące model obiektowy zadanego schematu bazy.

5.4. Komunikacja Matlab z projektem programistycznym

Poprawne skomunikowanie aplikacji bazodanowej ze środowiskiem obliczeniowym Matlab było najtrudniejszą częścią podczas całej pracy implementacyjnej. Podczas tworzenia architektury budowanej aplikacji, poszukiwany był efektywny sposób komunikacji środowiska .NET ze środowiskiem obliczeniowym Matlab. Przez fakt tego, iż systemy te utworzone zostały przez różnych producentów, nie ma prostego sposobu na ich sprzężenie. Poszukiwania doprowadziły do zastosowania biblioteki dedykowanej dla środowiska .NET opisanej w rozdziale 4.3.1, która łączy się z pośredniczącym serwerem Matlab. Serwer ten nie jest domyślnie dodawany przy instalacji środowiska obliczeniowego, dlatego też nachodzi konieczność jego dodatkowego doinstalowania. Biblioteka umożliwia stworzenie żądania na poziomie C#, które następnie przekazywane jest do serwera pośredniczącego tłumaczącego żądanie na język Matlab. Żądanie to jest wykonywane przez środowisko obliczeniowe, a jego rezultat analogiczną ścieżką jest przekazywany do aplikacji bazodanowej. Sporym problemem okazało się prawidłowe tworzenie żądań przez fakt na bardzo ograniczoną dokumentację biblioteki i małą liczbę przykładów. Na podstawie metody prób i błędów udało się jednak utworzyć prawidłowy typ żądań oraz w sposób właściwy dokonywać odbioru ich odpowiedzi. Żądanie w kodzie źródłowym numer (TODO: dodać alias kodu oraz kod metody wykonującej żądanie) prezentuje sposób wykonania pojedynczego doświadczenia dotyczącego algorytmu symulowanego wyżarzania, natomiast kod źródłowy numer (TODO: dodać alias kodu oraz kod metody parsującej wynik) ukazuje sposób przetwarzania otrzymanej odpowiedzi.

6. Badania eksperymentalne

Cały proces poczynszyszy od pomysłu automatyzacji przeprowadzanych badań zawarty w rozdziale 3, przez analizę rozwiązań technologicznych opisanych w rozdziale 4, po budowę architektury oraz samej aplikacji bazodanowej ujęty w rozdziale 5 miał za zadanie ułatwić przeprowadzenie eksperymentalnych badań porównawczych wybranych algorytmów metaheurystycznych. W obecnym rozdziale przedstawiony został opis metod porównawczych, a także samych badań doświadczalnych wraz z ich zagregowanymi wynikami zawartymi w 6.3.

6.1. Metody porównawcze wybranych algorytmów

W celu zrównania szans każdego z porównywanych algorytmów, wszystkie przeprowadzane testy dokonane zostały na tej samej maszynie obliczeniowej przy tych samych warunkach obciążeniowych systemu. Pierwszym kryterium porównawczym był maksymalny czas, w którym algorytm poszukuje najlepszego rezultatu. Parametr ten bierze pod uwagę kilka różnych ustalonych wartości dla których przeprowadzana została próbka doświadczeń, z których wartości średnie zostały zestawione i porównane w obrębie wszystkich algorytmów oraz funkcji testowych. Drugim kryterium porównawczym była liczba odwołań algorytmu do zadanej funkcji testowej. W kryterium tym porównane zostały, w sposób analogiczny jak w kryterium pierwszym, rezultaty otrzymane przez algorytmy przy takim założeniu, iż mogły one wyliczyć wartość funkcji testowej określoną liczbę razy.

6.2. Opis przeprowadzonych badań

6.2.1. Skalowanie algorytmów

Przez wzgląd na dużą liczbę parametrów każdego porównywanego algorytmu heurystycznego, zdecydowano się dokonać ich dostrojenia przed przeprowadzeniem zaplanowanych badań. Na bazie wybranych funkcji testowych wykonano liczne testy, na bazie których wybrano parametry, dla których uzyskano najlepsze rezultaty. Dla

algorytmu symulowanego wyżarzania jako metoda schładzająca, wybrana została standardowa funkcja

$$NowaTemperatura = ObecnaTemperatura * 0.95^k \quad (5)$$

, gdzie k jest numerem iteracji od wyżarzenia. Uwzględniając fakt dużej liczby iteracji, którą algorytm może wykonać podczas testów, zdecydowano się wprowadzić możliwość wystąpienia operacji ponownego wyżarzenia (ang. reannealing), w czasie której algorytm ponownie ustala temperaturę na domyślną wartość 100 i kontynuuje pracę. Wartość parametru ponownego wyżarzania ustalona została na poziomie 40 i definiuje liczbę punktów, które algorytm ma obowiązek zaakceptować przed wystąpieniem ponownego wyżarzenia. W metodzie roju cząstek domyślne parametry wzoru (TODO: numer wzoru 1) zawartego w rozdziale 2.2.1 ustalone zostały na następujące wartości: $W = 0.6$, $c_1 = c_2 = 0.75$. Algorytm genetyczny z kolei wymagał największej ilości testów skalujących przez fakt posiadania największej liczby możliwych kombinacji parametrów. Na ich podstawie wybrano metodę ruletki jako metodę selekcji, zastępowanie elitarne o wielkości elity równej $0.05 * WielkoscPopulacji$ jako metodę wymiany pokoleń oraz metodę krzyżowania dwudzielnego.

6.2.2. Przeprowadzenie doświadczeń w zaimplementowanym środowisku testowym

W zaimplementowanej aplikacji dla każdego opisanego w 6.1 kryterium, umieszczone zostały ustalone wartości parametrów, po czym przeprowadzana była operacja uruchomienia systemu. Dla kryterium maksymalnego czasu, w którym algorytmy poszukują globalnego minimum funkcji, doświadczenia wykonywane zostały dla zakresu od jednej do pięciu sekund, z jednosekundowym interwałem. Liczba testów dla każdej wartości z ustalonego zakresu ustalona została na poziomie stu prób. Pozostałe parametry, takie jak maksymalna liczba iteracji oraz odwołań do funkcji wraz z maksymalną liczbą iteracji bez poprawy wyniku, ustalone zostały na niemożliwą do osiągnięcia wartość 999999. Spowodowane jest to tym, iż jednym warunkiem stopu w przedstawianej metodzie porównawczej jest maksymalny ustalony czas działania algorytmu. W przypadku algorytmu genetycznego oraz roju cząstek dodatkowo przeprowadzone zostały doświadczenia dla różnych wielkości populacji i roju, dzięki czemu możliwa do wykonania była analiza wpływu tych parametrów na otrzymane rezultaty. Przeprowadzenie badań dotyczących kryterium maksymalnej

liczby odwołań do funkcji testowej przebiegało w sposób analogiczny, z tą różnicą, iż niemożliwą do osiągnięcia wartością 999999 został objęty maksymalny czas poszukiwań, który w opisywanym kryterium nie jest brany pod uwagę. Dla kryterium tego maksymalna liczba odwołań do funkcji ustalona została na wartości: 1000, 2000, 3000, 4000, 5000, 6000.

6.3. Wyniki doświadczeń dla zadanych funkcji testowych

Aktualny rozdział prezentuje zagregowane wyniki przeprowadzanych doświadczeń dla funkcji testowych opisanych w rozdziale 1.2. Prezentacja wyników dla każdej funkcji testowej podzielona została na dwie części przez wzgląd na dwa kryteria porównawcze algorytmów zdefiniowane w rozdziale 6.1. Wartym wspomnienia jest znaczenie kolorów tabel zawartych w poniższych podrozdziałach. Zielony kolor definiuje najlepsze otrzymane rezultaty w obrębie jednego testu, czerwony natomiast wyniki gorsze.

6.3.1. Funkcja Bohachevsky'ego 1

W tabeli 1 przedstawione zostały wyniki otrzymane przez algorytm genetyczny dla kryterium czasowego. Wynika z niej, iż najlepsze rezultaty uzyskane zostały dla wielkości populacji równej 100. Dla metody roju cząstek otrzymane rezultaty zaprezentowane zostały w tabeli 2, z której wynika, iż najlepsze wyniki uzyskane zostały dla wielkości roju równej 50 oraz 100. W tym jednak przypadku, jako najlepsze rezultaty wybrane zostały wyniki z wielkością roju równą 100, z powodu mniejszej liczby odwołań do funkcji testowej niż w przypadku roju o wielkości 50.

Najlepsze rezultaty algorytmu genetycznego oraz roju cząstek zostały zestawione wraz z rezultatami symulowanego wyżarzania w tabeli 3. Wynika z niej, iż najlepsze wyniki dla każdej wartości parametru maksymalnego czasu uzyskała metoda roju cząstek, która w każdym przypadku znalazła minimum globalne dla funkcji Bohachevsky'ego, którego wartość wynosi 0. Na drugim miejscu uplasował się algorytm genetyczny, którego wyniki oscylowały wokół minimum globalnego, jednak w ani jednym przypadku go nie osiągnęły. Algorytm symulowanego wyżarzania uzyskał lepszy rezultat od algorytmu genetycznego tylko w przypadku testów dotyczących maksymalnego czasu działania algorytmu równego jednej sekundzie. W pozostałych przypadkach uzyskał najgorsze rezultaty ze wszystkich porównywanych algorytmów

metaheurystycznych.

Maksymalny czas	Algorytm Genetyczny		
	Wielkość populacji	Wartość znalezionej minimum	Liczba odwołań do funkcji
1	10	0,50533	8954
2	10	0,27054	17538
3	10	0,25915	24586
4	10	0,35312	34576
5	10	0,43571	43202
6	10	0,81062	52668
1	50	0,08259	15110
2	50	0,16517	29850
3	50	0,00000	45130
4	50	0,00000	60150
5	50	0,08259	75440
6	50	0,00000	90160
1	100	0,07656	16100
2	100	0,00003	31660
3	100	0,00003	46740
4	100	0,00001	60200
5	100	0,00001	74320
6	100	0,00012	92580

Tabela 1: Zestawienie wyników algorytmu genetycznego dla funkcji Bohachevsky'ego
- kryterium czasowe, Źródło: Opracowanie własne.

	Metoda Roju Cząstek		
Maksymalny czas	Wielkość roju	Wartość znalezionej minimum	Liczba odwołań do funkcji
1	10	0,00002	27692
2	10	0,08259	57212
3	10	0,00003	83842
4	10	0,00002	119112
5	10	0,00001	148196
6	10	0,00002	177158
1	50	0,00000	41560
2	50	0,00000	83860
3	50	0,00000	126240
4	50	0,00000	170930
5	50	0,00000	214920
6	50	0,00000	259030
1	100	0,00000	37660
2	100	0,00000	73460
3	100	0,00000	102800
4	100	0,00000	132160
5	100	0,00000	180540
6	100	0,00000	215840

Tabela 2: Zestawienie wyników metody roju cząstek dla funkcji Bohachevsky'ego - kryterium czasowe, Źródło: Opracowanie własne.

Symulowane Wyżarzanie			
Maksymalny czas	Wartość znalezionej minimum		Liczba odwołań do funkcji
1	0,01978		2038
2	0,00950		3937
3	0,00211		5958
4	0,00349		7755
5	0,00095		9713
6	0,00024		11644
Algorytm Genetyczny			
Maksymalny czas	Wielkość populacji	Wartość znalezionej minimum	Liczba odwołań do funkcji
1	100	0,17656	16100
2	100	0,00003	31660
3	100	0,00003	46740
4	100	0,00001	60200
5	100	0,00001	74320
6	100	0,00012	92580
Metoda Roju Częstek			
Maksymalny czas	Wielkość roju	Wartość znalezionej minimum	Liczba odwołań do funkcji
1	100	0,00000	37660
2	100	0,00000	73460
3	100	0,00000	102800
4	100	0,00000	132160
5	100	0,00000	180540
6	100	0,00000	215840

Tabela 3: Zestawienie najlepszych wyników wszystkich trzech porównywanych algorytmów metaheurystycznych dla funkcji Bohachevsky'ego - kryterium czasowe, Źródło: Opracowanie własne.

W przypadku kryterium dotyczącym określonej maksymalnej liczby odwołań algorytmu do funkcji testowej, otrzymane rezultaty są bardzo zbliżone do rezultatów poprzedniego kryterium. Algorytm genetyczny najlepsze wyniki uzyskał dla wielkości populacji równej 100, co można zaobserwować na wykresie 4. Metoda roju cząstek, według wykresu 5, najlepsze rezultaty zanotowała dla wielkości roju równego 50, co jest inną wartością niż w przypadku kryterium czasowego. Wyniki te zostały zestawione w tabeli 6 z rezultatami otrzymanymi przez algorytm symulowanego wyżarzania, z której wynika iż ponownie dla każdej wartości zadanego kryterium, najlepsza okazała się metoda roju cząstek.

Liczba odwołań do funkcji	Algorytm Genetyczny		
	Wielkość populacji	Wartość znalezionej minimum	Liczba generacji
1000	10	0,27054	100
2000	10	0,58187	200
3000	10	0,25345	300
4000	10	0,35312	400
5000	10	0,22355	500
6000	10	0,08828	600
1000	50	0,05025	20
2000	50	0,04699	40
3000	50	0,08828	60
4000	50	0,22875	80
5000	50	0,00000	100
6000	50	0,04699	120
1000	100	0,03825	10
2000	100	0,00374	20
3000	100	0,00016	30
4000	100	0,00000	40
5000	100	0,00000	50
6000	100	0,00000	60

Tabela 4: Zestawienie wyników algorytmu genetycznego dla funkcji Bohachevsky'ego - kryterium liczby odwołań do funkcji testowej, Źródło: Opracowanie własne., Źródło: Opracowanie własne.

	Metoda Roju Cząstek		
Liczba odwołań do funkcji	Wielkość roju	Wartość znalezionego minimum	Liczba iteracji
1000	10	0,09398	100
2000	10	0,00000	200
3000	10	0,04699	300
4000	10	0,00000	400
5000	10	0,00000	500
6000	10	0,00000	600
1000	50	0,02503	20
2000	50	0,00000	40
3000	50	0,00000	60
4000	50	0,00000	80
5000	50	0,00000	100
6000	50	0,00000	120
1000	100	0,37419	10
2000	100	0,00316	20
3000	100	0,00003	30
4000	100	0,00000	40
5000	100	0,00000	50
6000	100	0,00000	60

Tabela 5: Zestawienie wyników metody roju cząstek dla funkcji Bohachevsky'ego - kryterium liczby odwołań do funkcji testowej, Źródło: Opracowanie własne.

Symulowane Wyżarzanie			
Liczba odwołań do funkcji	Wartość znalezionej minimum		Liczba iteracji
1000	0,15152		1000
2000	0,04706		2000
3000	0,00492		3000
4000	0,00325		4000
5000	0,00230		5000
6000	0,00217		6000
Algorytm Genetyczny			
Liczba odwołań do funkcji	Wielkość populacji	Wartość znalezionej minimum	Liczba generacji
1000	100	0,03825	10
2000	100	0,00374	20
3000	100	0,00016	30
4000	100	0,00000	40
5000	100	0,00000	50
6000	100	0,00000	60
Metoda Roju Częstek			
Liczba odwołań do funkcji	Wielkość roju	Wartość znalezionej minimum	Liczba iteracji
1000	50	0,02503	20
2000	50	0,00000	40
3000	50	0,00000	60
4000	50	0,00000	80
5000	50	0,00000	100
6000	50	0,00000	120

Tabela 6: Zestawienie najlepszych wyników wszystkich trzech porównywanych algorytmów metaheurystycznych dla funkcji Bohachevsky'ego - kryterium liczby odwołań do funkcji testowej, Źródło: Opracowanie własne.

6.3.2. Funkcja Colville'a

Dla funkcji Colville'a, wyniki testów sprawdzających optymalną wielkość populacji dla algorytmu genetycznego przedstawione zostały w tabeli 7, z której wynika, iż najbliższej minimum globalnego dla kryterium czasowego uplasowały się rezultaty z wielkością populacji równą 100. Taka sama wartość została ustalona dla analogicznego testu sprawdzającego optymalną wielkość roju dla metody roju cząstek

widocznego na wykresie 8. Wyniki obu testów zostały zestawione z rezultatami otrzymanymi przez algorytm symulowanego wyżarzania na wykresie 9. Z wykresu tego wynika, iż najbliższej wartości 0, która jest minimum globalnym badanej funkcji, uplasowały się rezultaty otrzymane przez metodę roju cząstek. Wyniki otrzymane przez algorytm genetyczny uplasowały go na drugim miejscu, przed algorytmem symulowanego wyżarzania, którego rezultaty były bardzo odległe od poszukiwanego minimum globalnego.

Maksymalny czas	Algorytm Genetyczny		
	Wielkość populacji	Wartość znalezionej minimum	Liczba odwołań do funkcji
1	10	1,01206	8800
2	10	0,64249	17748
3	10	2,44841	26264
4	10	0,10143	34958
5	10	1,11109	44078
6	10	0,19459	52572
1	50	2,21722	14340
2	50	0,46911	29940
3	50	0,10756	43730
4	50	0,10229	59420
5	50	0,06617	74080
6	50	1,57922	88530
1	100	0,37593	15560
2	100	0,15028	31020
3	100	0,04512	46540
4	100	0,08684	61880
5	100	0,05409	77520
6	100	0,05227	93120

Tabela 7: Zestawienie wyników algorytmu genetycznego dla funkcji Colville'a - kryterium czasowe, Źródło: Opracowanie własne.

	Metoda Roju Cząstek		
Maksymalny czas	Wielkość roju	Wartość znalezionej minimum	Liczba odwołań do funkcji
1	10	0,04142	27380
2	10	0,00701	55344
3	10	0,00009	83208
4	10	0,00002	109760
5	10	0,00000	139726
6	10	0,00000	167042
1	50	0,00243	46050
2	50	0,01416	92180
3	50	0,00005	136090
4	50	0,00005	181070
5	50	0,00000	228990
6	50	0,00000	276880
1	100	0,00241	42060
2	100	0,00023	85780
3	100	0,00002	128740
4	100	0,00003	170920
5	100	0,00000	213840
6	100	0,00000	261920

Tabela 8: Zestawienie wyników metody roju cząstek dla funkcji Colville'a - kryterium czasowe, Źródło: Opracowanie własne.

Symulowane Wyżarzanie			
Maksymalny czas	Wartość znalezionej minimum		Liczba odwołań do funkcji
1	114,10349		1789
2	58,08332		3552
3	21,16509		5197
4	10,04012		6959
5	1,23721		8606
6	0,19772		10247
Algorytm Genetyczny			
Maksymalny czas	Wielkość populacji	Wartość znalezionej minimum	Liczba odwołań do funkcji
1	100	0,37593	15560
2	100	0,15028	31020
3	100	0,04512	46540
4	100	0,08684	61880
5	100	0,05409	77520
6	100	0,05227	93120
Metoda Roju Częstek			
Maksymalny czas	Wielkość roju	Wartość znalezionej minimum	Liczba odwołań do funkcji
1	100	0,00241	42060
2	100	0,00023	85780
3	100	0,00002	128740
4	100	0,00003	170920
5	100	0,00000	213840
6	100	0,00000	261920

Tabela 9: Zestawienie najlepszych wyników wszystkich trzech porównywanych algorytmów metaheurystycznych dla funkcji Colville'a - kryterium czasowe, Źródło: Opracowanie własne.

Rezultaty dotyczące testów dla kryterium odnoszącego się do maksymalnej liczby odwołań algorytmu do funkcji testowej okazały się bardzo ciekawe przez wzgląd na uzyskanie najlepszych rezultatów przez inny algorytm niż w kryterium poprzednim. Do podsumowującego testu wszystkich trzech algorytmów metaheurystycznych zostały wybrane dla algorytmu genetycznego rezultaty przedstawione w tabeli 10 z wielkością populacji równą 100, natomiast dla metody roju cząstek wyniki z wielkością roju równą 10, które dostępne są do wglądu w tabli 11. Podsumowanie widoczne w tabeli 12 pozwala dostrzec, iż najlepsze wyniki uzyskał algorytm genetyczny, który w testach pierwszego kryterium uzyskał drugi rezultat. Porównując wyniki dla obu kryteriów porównawczych z tabel 9 oraz 12, widoczna jest zależność wyjaśniająca taki efekt. Metoda roju cząstek przeprowadza znacznie więcej odwołań do badanej funkcji Colville'a niż algorytm genetyczny dla tego samego czasu pracy algorytmów. Z tego powodu przy limicie owych odwołań w kryterium drugim, wyniki otrzyma-

ne przez algorytm genetyczny są lepsze. Wartym wspomnienia jest także to, iż w analizowanym przykładzie wyniki uzyskane przez metodę roju cząstek są nie tylko gorsze od wyników uzyskanych przez algorytm genetyczny, lecz także przez symulowane wyżarzanie, które to uzyskało drugi rezultat dla każdego badanego parametru maksymalnej liczby odwołań do funkcji testowej.

Liczba odwołań do funkcji	Algorytm Genetyczny		
	Wielkość populacji	Wartość znalezionej minimum	Liczba generacji
1000	10	3,20273	100
2000	10	3,94219	200
3000	10	5,05571	300
4000	10	2,25915	400
5000	10	2,17518	500
6000	10	1,68003	600
1000	50	3,60476	20
2000	50	1,80067	40
3000	50	1,59701	60
4000	50	2,04576	80
5000	50	0,94703	100
6000	50	2,45713	120
1000	100	2,54692	10
2000	100	1,47420	20
3000	100	1,44208	30
4000	100	1,25604	40
5000	100	0,99649	50
6000	100	0,66766	60

Tabela 10: Zestawienie wyników algorytmu genetycznego dla funkcji Colville'a - kryterium liczby odwołań do funkcji testowej, Źródło: Opracowanie własne., Źródło: Opracowanie własne.

	Metoda Roju Cząstek		
Liczba odwołań do funkcji	Wielkość roju	Wartość znalezionej minimum	Liczba iteracji
1000	10	399,68527	100
2000	10	148,28911	200
3000	10	2,29084	300
4000	10	1,51750	400
5000	10	1,21875	500
6000	10	1,19613	600
1000	50	2786,25419	20
2000	50	152,12862	40
3000	50	3,18737	60
4000	50	1,58407	80
5000	50	1,58627	100
6000	50	1,83847	120
1000	100	4289,10984	10
2000	100	1135,85957	20
3000	100	265,14082	30
4000	100	7,98078	40
5000	100	1,98679	50
6000	100	1,55706	60

Tabela 11: Zestawienie wyników metody roju cząstek dla funkcji Colville'a - kryterium liczby odwołań do funkcji testowej, Źródło: Opracowanie własne.

Symulowane Wyżarzanie			
Liczba odwołań do funkcji	Wartość znalezionej minimum		Liczba iteracji
1000	68,74295		1000
2000	46,06927		2000
3000	2,16472		3000
4000	1,44973		4000
5000	1,11868		5000
6000	0,91541		6000
Algorytm Genetyczny			
Liczba odwołań do funkcji	Wielkość populacji	Wartość znalezionej minimum	Liczba generacji
1000	100	2,54692	10
2000	100	1,47420	20
3000	100	1,44208	30
4000	100	1,25604	40
5000	100	0,99649	50
6000	100	0,66766	60
Metoda Roju Cząstek			
Liczba odwołań do funkcji	Wielkość roju	Wartość znalezionej minimum	Liczba iteracji
1000	10	399,68527	100
2000	10	148,28911	200
3000	10	2,29084	300
4000	10	1,51750	400
5000	10	1,21875	500
6000	10	1,19613	600

Tabela 12: Zestawienie najlepszych wyników wszystkich trzech porównywanych algorytmów metaheurystycznych dla funkcji Colville'a - kryterium liczby odwołań do funkcji testowej, Źródło: Opracowanie własne.

6.3.3. Funkcja Ackley'a

Kolejną funkcją, która poddana została testom jest funkcja Ackleya, dla której algorytm genetyczny oraz metoda roju cząstek dla kryterium czasowego uzyskała najlepsze rezultaty dla wielkości populacji oraz roju wynoszącej 50. Wyniki te, dostępne do wglądu w tabeli 13 oraz 14, zestawione zostały w tabeli 15 z wynikami otrzymanymi przez algorytm symulowanego wyżarzania. Z podsumowania

tego jednoznacznie wynika, iż dla każdego badanego parametru maksymalnego czasu algorytm genetyczny zwrócił najlepsze rezultaty, które to są bardzo zbliżone do minimum globalnego wynoszącego 0. Pozostałe algorytmy nawet nie zbliżyły się do tych rezultatów i utknęły minimach lokalnych funkcji.

	Algorytm Genetyczny		
Maksymalny czas	Wielkość populacji	Wartość znalezionej minimum	Liczba odwołań do funkcji
1	10	1,48507	8698
2	10	1,41709	17464
3	10	1,65735	26128
4	10	1,74368	34772
5	10	1,65734	42662
6	10	0,99338	52302
1	50	0,00003	14520
2	50	0,00001	27170
3	50	0,36800	37160
4	50	0,00001	54810
5	50	0,00000	66790
6	50	0,00000	75070
1	100	1,10400	15220
2	100	0,00001	31020
3	100	0,00001	46000
4	100	0,00004	61300
5	100	0,00000	76920
6	100	0,51599	93060

Tabela 13: Zestawienie wyników algorytmu genetycznego dla funkcji Ackley'a - kryterium czasowe, Źródło: Opracowanie własne.

	Metoda Roju Cząstek		
Maksymalny czas	Wielkość roju	Wartość znalezionej minimum	Liczba odwołań do funkcji
1	10	20,00000	28114
2	10	20,00000	55876
3	10	20,00000	84280
4	10	20,00000	112162
5	10	20,00000	141600
6	10	20,00000	171352
1	50	19,99956	39140
2	50	19,99956	69480
3	50	19,99956	108790
4	50	16,51610	156580
5	50	16,71478	196910
6	50	19,99956	238150
1	100	20,00000	33760
2	100	20,00000	70500
3	100	20,00000	105040
4	100	20,00000	139960
5	100	20,00000	176480
6	100	20,00000	212060

Tabela 14: Zestawienie wyników metody roju cząstek dla funkcji Ackley'a - kryterium czasowe, Źródło: Opracowanie własne.

Symulowane Wyżarzanie			
Maksymalny czas	Wartość znalezionej minimum		Liczba odwołań do funkcji
1	19,99956		2038
2	20,00000		3937
3	20,00000		5958
4	16,85489		7755
5	19,84388		9713
6	19,99997		11644
Algorytm Genetyczny			
Maksymalny czas	Wielkość populacji	Wartość znalezionej minimum	Liczba odwołań do funkcji
1	50	0,00003	14520
2	50	0,00001	27170
3	50	0,36800	37160
4	50	0,00001	54810
5	50	0,00000	66790
6	50	0,00000	75070
Metoda Roju Częstek			
Maksymalny czas	Wielkość roju	Wartość znalezionej minimum	Liczba odwołań do funkcji
1	50	19,99956	39140
2	50	19,99956	69480
3	50	19,99956	108790
4	50	16,51610	156580
5	50	16,71478	196910
6	50	19,99956	238150

Tabela 15: Zestawienie najlepszych wyników wszystkich trzech porównywanych algorytmów metaheurystycznych dla funkcji Ackley'a - kryterium czasowe, Źródło: Opracowanie własne.

Wyniki dotyczące kryterium limitu odwołań do funkcji testowej są analogiczne jak w przypadku pierwszego kryterium. Jediną różnicą są wielkości populacji oraz roju, których wyniki zostały wzięte do testu podsumowującego widocznego w tabeli 18. Funkcja Ackley'a jest pierwszą testowaną funkcją, do której minimum globalnego w obu badanych kryteriach zbliżył się tylko jeden porównywany algorytm metaheurystyczny - algorytm genetyczny.

Liczba odwołań do funkcji	Algorytm Genetyczny		
	Wielkość populacji	Wartość znalezionej minimum	Liczba generacji
1000	10	1,48507	100
2000	10	1,41709	200
3000	10	1,65735	300
4000	10	1,74368	400
5000	10	1,65734	500
6000	10	0,99338	600
1000	50	1,44904	20
2000	50	0,35100	40
3000	50	0,00291	60
4000	50	0,18426	80
5000	50	0,44204	100
6000	50	0,00006	120
1000	100	0,61431	10
2000	100	0,30613	20
3000	100	0,00074	30
4000	100	0,01294	40
5000	100	0,00501	50
6000	100	0,00000	60

Tabela 16: Zestawienie wyników algorytmu genetycznego dla funkcji Ackley'a - kryterium liczby odwołań do funkcji testowej, Źródło: Opracowanie własne., Źródło: Opracowanie własne.

Liczba odwołań do	Metoda Roju Cząstek		
	Wielkość roju	Wartość znalezionej minimum	Liczba iteracji
1000	10	20,00000	100
2000	10	20,00000	200
3000	10	20,00000	300
4000	10	20,00000	400
5000	10	20,00000	500
6000	10	20,00000	600
1000	50	20,00000	20
2000	50	20,00000	40
3000	50	20,00000	60
4000	50	20,00000	80
5000	50	20,00000	100
6000	50	20,00000	120
1000	100	19,99956	10
2000	100	19,99956	20
3000	100	19,99956	30
4000	100	19,99956	40
5000	100	19,27688	50
6000	100	18,18411	60

Tabela 17: Zestawienie wyników metody roju cząstek dla funkcji Ackley'a - kryterium liczby odwołań do funkcji testowej, Źródło: Opracowanie własne.

Symulowane Wyżarzanie			
Liczba odwołań do funkcji	Wartość znalezionej minimum		Liczba iteracji
1000	19,99956		1000
2000	19,99956		2000
3000	19,84388		3000
4000	18,21715		4000
5000	16,85489		5000
6000	12,52854		6000
Algorytm Genetyczny			
Liczba odwołań do funkcji	Wielkość populacji	Wartość znalezionej minimum	Liczba generacji
1000	100	0,61431	10
2000	100	0,30613	20
3000	100	0,00074	30
4000	100	0,01294	40
5000	100	0,00501	50
6000	100	0,00000	60
Metoda Roju Częstek			
Liczba odwołań do funkcji	Wielkość roju	Wartość znalezionej minimum	Liczba iteracji
1000	100	19,99956	10
2000	100	19,99956	20
3000	100	19,99956	30
4000	100	19,99956	40
5000	100	19,27688	50
6000	100	18,18411	60

Tabela 18: Zestawienie najlepszych wyników wszystkich trzech porównywanych algorytmów metaheurystycznych dla funkcji Ackley'a - kryterium liczby odwołań do funkcji testowej, Źródło: Opracowanie własne.

6.3.4. Funkcja Rosenbrocka

Funkcja Rosenbrocka jest pierwszą funkcją w której analizując ustalone kryterium, otrzymane najlepsze rezultaty nie należą do jednego algorytmu heurystycznego. Po wyborze optymalnych wielkości populacji oraz roju dla kryterium czasowego, których testy dostępne są do wglądu w tabeli 25 oraz 26, dokonano zestawienia najlepszych rezultatów wszystkich trzech algorytmów w tabeli 27. Wynika z niej, iż dla

wartości maksymalnego czasu od 1 do 3, najlepsze rezultaty uzyskała metoda roju cząstek, podczas gdy dla wyższych z zakresu 4 do 6 - algorytm genetyczny.

	Algorytm Genetyczny		
Maksymalny czas	Wielkość populacji	Wartość znalezionej minimum	Liczba odwołań do funkcji
1	10	0,82550	8772
2	10	0,26159	17590
3	10	0,82115	26534
4	10	0,74509	35322
5	10	1,02229	43770
6	10	0,00199	52470
1	50	1,53272	14770
2	50	0,76142	29360
3	50	1,53482	42960
4	50	0,00562	57480
5	50	2,88337	72960
6	50	0,00729	87580
1	100	0,12195	15420
2	100	0,03372	30760
3	100	0,24795	47360
4	100	0,00470	61760
5	100	0,80783	78420
6	100	0,00102	93740

Tabela 19: Zestawienie wyników algorytmu genetycznego dla funkcji Rosenbrocka - kryterium czasowe, Źródło: Opracowanie własne.

	Metoda Roju Cząstek		
Maksymalny czas	Wielkość roju	Wartość znalezionej minimum	Liczba odwołań do funkcji
1	10	0,92458	27340
2	10	20,76899	54880
3	10	59,03184	83430
4	10	3,61168	102100
5	10	4,49411	138022
6	10	18,06645	162724
1	50	0,06268	46010
2	50	0,00618	91690
3	50	0,00009	136180
4	50	2,03191	182110
5	50	3,94942	228490
6	50	10,89048	272280
1	100	0,18802	42160
2	100	41,31897	83840
3	100	8,63839	127680
4	100	5,50275	166720
5	100	4,95079	208280
6	100	11,04257	235120

Tabela 20: Zestawienie wyników metody roju cząstek dla funkcji Rosenbrocka - kryterium czasowe, Źródło: Opracowanie własne.

Symulowane Wyżarzanie			
Maksymalny czas	Wartość znalezionej minimum		Liczba odwołań do funkcji
1	254,15459		1937
2	162,15133		3860
3	2407,35639		5771
4	27,87462		7621
5	1710,39496		9439
6	2712,85974		11110
Algorytm Genetyczny			
Maksymalny czas	Wielkość populacji	Wartość znalezionej minimum	Liczba odwołań do funkcji
1	100	0,12195	15420
2	100	0,03372	30760
3	100	0,24795	47360
4	100	0,00470	61760
5	100	0,80783	78420
6	100	0,00102	93740
Metoda Roju Cząstek			
Maksymalny czas	Wielkość roju	Wartość znalezionej minimum	Liczba odwołań do funkcji
1	50	0,06268	46010
2	50	0,00618	91690
3	50	0,00009	136180
4	50	2,03191	182110
5	50	3,94942	228490
6	50	10,89048	272280

Tabela 21: Zestawienie najlepszych wyników wszystkich trzech porównywanych algorytmów metaheurystycznych dla funkcji Rosenbrocka - kryterium czasowe, Źródło: Opracowanie własne.

Dla drugiego analizowanego kryterium dotyczącego ustalonej maksymalnej liczby odwołań do funkcji testowej, rezultaty, które dostępne są do wglądu w tabeli 30 okazały się już bardziej jednolite. Algorytm genetyczny dla wielkości populacji równej 50 (tabela 28) osiągnął lepsze rezultaty od metody roju cząstek z wielkością roju równą 10 (tabela 29) dla każdego przeprowadzonego testu.

Liczba odwołań do funkcji	Algorytm Genetyczny		
	Wielkość populacji	Wartość znalezionej minimum	Liczba generacji
1000	10	11,42978	100
2000	10	2,08431	200
3000	10	0,72318	300
4000	10	2,09036	400
5000	10	1,65619	500
6000	10	1,34928	600
1000	50	12,04365	20
2000	50	0,89409	40
3000	50	0,95516	60
4000	50	1,11253	80
5000	50	0,92540	100
6000	50	1,08177	120
1000	100	20,15711	10
2000	100	1,83451	20
3000	100	0,96928	30
4000	100	1,85377	40
5000	100	1,71043	50
6000	100	1,10941	60

Tabela 22: Zestawienie wyników algorytmu genetycznego dla funkcji Rosenbrocka - kryterium liczby odwołań do funkcji testowej, Źródło: Opracowanie własne., Źródło: Opracowanie własne.

	Metoda Roju Cząstek		
Liczba odwołań do funkcji	Wielkość roju	Wartość znalezionej minimum	Liczba iteracji
1000	10	34,72416	100
2000	10	35,15995	200
3000	10	40,64258	300
4000	10	103,63134	400
5000	10	23,92185	500
6000	10	32,38185	600
1000	50	248,14856	20
2000	50	191,35804	40
3000	50	217,19964	60
4000	50	127,14346	80
5000	50	24,90371	100
6000	50	133,61537	120
1000	100	165,99137	10
2000	100	300,72208	20
3000	100	117,06707	30
4000	100	56,55604	40
5000	100	30,80656	50
6000	100	42,39143	60

Tabela 23: Zestawienie wyników metody roju cząstek dla funkcji Rosenbrocka - kryterium liczby odwołań do funkcji testowej, Źródło: Opracowanie własne.

Symulowane Wyżarzanie			
Liczba odwołań do funkcji	Wartość znalezionej minimum		Liczba iteracji
1000	403,21334		1000
2000	333,77587		2000
3000	412,82061		3000
4000	163,51327		4000
5000	126,54864		5000
6000	124,45350		6000
Algorytm Genetyczny			
Liczba odwołań do funkcji	Wielkość populacji	Wartość znalezionej minimum	Liczba generacji
1000	50	12,04365	20
2000	50	0,89409	40
3000	50	0,95516	60
4000	50	1,11253	80
5000	50	0,92540	100
6000	50	1,08177	120
Metoda Roju Cząstek			
Liczba odwołań do funkcji	Wielkość roju	Wartość znalezionej minimum	Liczba iteracji
1000	10	34,72416	100
2000	10	35,15995	200
3000	10	40,64258	300
4000	10	103,63134	400
5000	10	23,92185	500
6000	10	32,38185	600

Tabela 24: Zestawienie najlepszych wyników wszystkich trzech porównywanych algorytmów metaheurystycznych dla funkcji Rosenbrocka - kryterium liczby odwołań do funkcji testowej, Źródło: Opracowanie własne.

6.3.5. Funkcja Eggholdera

Czwartą z kolei funkcją jest funkcja Eggholdera, dla której rezultaty testów weryfikujących optymalną wartość populacji oraz roju cząstek zaprezentowane zostały na wykresach 19 oraz 20. Dla obu algorytmów w kontekście testów dotyczących kryterium maksymalnego czasu, wartości te zostały ustalone na poziomie 100. Ich rezultaty, wraz z rezultatami otrzymanymi dla algorytmu symulowanego wyżarzania

zgrupowane zostały na wykresie 21. Analizując wykres można dostrzec, iż metoda roju cząstek poradziła sobie najlepiej, oscylując bardzo blisko minimum globalnego funkcji Eggholdera, które wynosi $-959,6407$. Tuż za rojem cząstek uplasował się algorytm genetyczny, którego rezultaty osiągały średnio wartość bliską wartości -900 . Wynik ten jest wciąż dużo lepszy od wyników zwróconych przez algorytm symulowanego wyżarzania, który zatrzymywał się na poziomie wartości około -500 .

Maksymalny czas	Algorytm Genetyczny		
	Wielkość populacji	Wartość znalezionej minimum	Liczba odwołań do funkcji
1	10	-641,37362	8249
2	10	-710,10740	17046
3	10	-743,86777	25225
4	10	-689,52398	34094
5	10	-665,27107	40654
6	10	-705,61882	48645
1	50	-806,45333	14575
2	50	-807,15515	28455
3	50	-881,24751	43720
4	50	-842,77199	57395
5	50	-839,99882	70320
6	50	-874,10131	82395
1	100	-899,91582	14790
2	100	-906,98633	31170
3	100	-899,75344	44990
4	100	-905,75450	63010
5	100	-895,72991	79950
6	100	-918,98375	93610

Tabela 25: Zestawienie wyników algorytmu genetycznego dla funkcji Eggholdera - kryterium czasowe, Źródło: Opracowanie własne.

	Metoda Roju Cząstek		
Maksymalny czas	Wielkość roju	Wartość znalezionej minimum	Liczba odwołań do funkcji
1	10	-949,53672	28617
2	10	-911,91620	58934
3	10	-907,80450	87470
4	10	-928,62314	118262
5	10	-946,06533	152606
6	10	-940,60027	178690
1	50	-959,64066	42620
2	50	-959,64066	85915
3	50	-953,13449	128705
4	50	-953,13449	173690
5	50	-959,64066	219210
6	50	-959,64066	260525
1	100	-959,64066	36350
2	100	-959,64066	73340
3	100	-959,64066	111470
4	100	-959,64066	148230
5	100	-959,64066	183010
6	100	-959,64066	215380

Tabela 26: Zestawienie wyników metody roju cząstek dla funkcji Eggholdera - kryterium czasowe, Źródło: Opracowanie własne.

Symulowane Wyżarzanie			
Maksymalny czas	Wartość znalezionej minimum		Liczba odwołań do funkcji
1	-507,29728		1623
2	-477,46049		3105
3	-496,56648		4954
4	-590,61418		6649
5	-503,45821		8457
6	-496,50273		9105
Algorytm Genetyczny			
Maksymalny czas	Wielkość populacji	Wartość znalezionej minimum	Liczba odwołań do funkcji
1	100	-899,91582	14790
2	100	-906,98633	31170
3	100	-899,75344	44990
4	100	-905,75450	63010
5	100	-895,72991	79950
6	100	-918,98375	93610
Metoda Roju Częstek			
Maksymalny czas	Wielkość roju	Wartość znalezionej minimum	Liczba odwołań do funkcji
1	100	-959,64066	36350
2	100	-959,64066	73340
3	100	-959,64066	111470
4	100	-959,64066	148230
5	100	-959,64066	183010
6	100	-959,64066	215380

Tabela 27: Zestawienie najlepszych wyników wszystkich trzech porównywanych algorytmów metaheurystycznych dla funkcji Eggholdera - kryterium czasowe, Źródło: Opracowanie własne.

Przechodząc do drugiego analizowanego kryterium - maksymalnej liczby odwołań do funkcji - można zaobserwować, iż wyniki są bardzo zbliżone do wyników otrzymanych w kryterium pierwszym. Testy badające optymalną wielkość populacji dla algorytmu genetycznego oraz wielkości roju dla metody roju cząstek dostępne są do wglądu na wykresie 22 oraz 23, natomiast testy porównujące wszystkie trzy badane algorytmy heurystyczne na wykresie 24.

Liczba odwołań do funkcji	Algorytm Genetyczny		
	Wielkość populacji	Wartość znalezionej minimum	Liczba generacji
1000	10	-652,59142	100
2000	10	-739,09817	200
3000	10	-659,72212	300
4000	10	-712,86772	400
5000	10	-597,89480	500
6000	10	-633,92186	600
1000	50	-815,88664	20
2000	50	-852,23377	40
3000	50	-823,89477	60
4000	50	-866,67945	80
5000	50	-822,23638	100
6000	50	-800,93763	120
1000	100	-869,40202	10
2000	100	-864,24074	20
3000	100	-905,17581	30
4000	100	-898,60492	40
5000	100	-915,98754	50
6000	100	-882,63617	60

Tabela 28: Zestawienie wyników algorytmu genetycznego dla funkcji Egggholdera - kryterium liczby odwołań do funkcji testowej, Źródło: Opracowanie własne., Źródło: Opracowanie własne.

Liczba odwołań do funkcji	Metoda Roju Cząstek		
	Wielkość roju	Wartość znalezionej minimum	Liczba iteracji
1000	10	-925,67409	100
2000	10	-914,77872	200
3000	10	-933,05286	300
4000	10	-904,80550	400
5000	10	-914,48484	500
6000	10	-915,04781	600
1000	50	-959,07401	20
2000	50	-959,58579	40
3000	50	-953,13449	60
4000	50	-959,64066	80
5000	50	-959,64066	100
6000	50	-959,64066	120
1000	100	-959,64066	10
2000	100	-959,64066	20
3000	100	-959,64066	30
4000	100	-959,64066	40
5000	100	-959,64066	50
6000	100	-959,64066	60

Tabela 29: Zestawienie wyników metody roju cząstek dla funkcji Eggholdera - kryterium liczby odwołań do funkcji testowej, Źródło: Opracowanie własne.

Symulowane Wyżarzanie			
Liczba odwołań do funkcji	Wartość znalezione minimum		Liczba iteracji
1000	-480,19223		1000
2000	-473,27827		2000
3000	-486,51610		3000
4000	-489,33426		4000
5000	-543,22278		5000
6000	-619,15628		6000
Algorytm Genetyczny			
Liczba odwołań do funkcji	Wielkość populacji	Wartość znalezione minimum	Liczba generacji
1000	100	-869,40202	10
2000	100	-864,24074	20
3000	100	-905,17581	30
4000	100	-898,60492	40
5000	100	-915,98754	50
6000	100	-882,63617	60
Metoda Roju Cząstek			
Liczba odwołań do funkcji	Wielkość roju	Wartość znalezione minimum	Liczba iteracji
1000	100	-959,64066	10
2000	100	-959,64066	20
3000	100	-959,64066	30
4000	100	-959,64066	40
5000	100	-959,64066	50
6000	100	-959,64066	60

Tabela 30: Zestawienie najlepszych wyników wszystkich trzech porównywanych algorytmów metaheurystycznych dla funkcji Eggholdera - kryterium liczby odwołań do funkcji testowej, Źródło: Opracowanie własne.

6.3.6. Funkcja Griewanka

Ostatnią użytą funkcją testową była funkcja Griewanka, dla której podobnie jak w przypadku funkcji Rosenbrocka rezultaty otrzymane dla kryterium maksymalnego czasu nie są jednoznaczne. Porównując najlepsze wyniki otrzymane dla algorytmu genetycznego z tabeli 31 oraz dla metody roju cząstek z tabeli 32 z wynikami otrzymanymi przez algorytm symulowanego wyżarzania, można dostrzec w

tabeli 33, iż lepszy rezultat otrzymany w teście 1 oraz 3 sekund należy do algorytmu genetycznego, a dla pozostałych wartości maksymalnego czasu dla metody roju cząstek. Otrzymane przez algorytm genetyczny oraz metodę roju cząstek rezultaty są jednak bardzo do siebie zbliżone i nie mogą jednoznacznie determinować lepszego algorytmu do zastosowania.

Maksymalny czas	Algorytm Genetyczny		
	Wielkość populacji	Wartość znalezionej minimum	Liczba odwołań do funkcji
1	10	0,01380	8684
2	10	0,04242	17494
3	10	0,03403	26182
4	10	0,10179	35348
5	10	0,09381	43874
6	10	0,00497	50872
1	50	0,09815	14280
2	50	0,03550	27960
3	50	0,02316	42270
4	50	0,06786	58340
5	50	0,06254	73200
6	50	0,00448	86740
1	100	0,00148	15400
2	100	0,01035	31040
3	100	0,00592	46460
4	100	0,00592	61160
5	100	0,00789	77700
6	100	0,00395	93600

Tabela 31: Zestawienie wyników algorytmu genetycznego dla funkcji Griewanka - kryterium czasowe, Źródło: Opracowanie własne.

	Metoda Roju Cząstek		
Maksymalny czas	Wielkość roju	Wartość znalezionej minimum	Liczba odwołań do funkcji
1	10	0,00790	27728
2	10	0,00592	55890
3	10	0,00987	84976
4	10	0,01627	114240
5	10	0,01232	140956
6	10	0,03450	172454
1	50	0,02194	41530
2	50	0,00787	78980
3	50	0,00739	125790
4	50	0,00542	159940
5	50	0,00493	195560
6	50	0,00542	242800
1	100	0,00296	37520
2	100	0,00591	72440
3	100	0,00641	103300
4	100	0,00197	142220
5	100	0,00197	181280
6	100	0,00148	218700

Tabela 32: Zestawienie wyników metody roju cząstek dla funkcji Griewanka - kryterium czasowe, Źródło: Opracowanie własne.

Symulowane Wyżarzanie			
Maksymalny czas	Wartość znalezionej minimum		Liczba odwołań do funkcji
1	0,71977		2002
2	0,19232		3888
3	0,15288		5809
4	0,16766		7711
5	0,12635		9616
6	0,11727		11396
Algorytm Genetyczny			
Maksymalny czas	Wielkość populacji	Wartość znalezionej minimum	Liczba odwołań do funkcji
1	100	0,00148	15400
2	100	0,01035	31040
3	100	0,00592	46460
4	100	0,00592	61160
5	100	0,00789	77700
6	100	0,00395	93600
Metoda Roju Cząstek			
Maksymalny czas	Wielkość roju	Wartość znalezionej minimum	Liczba odwołań do funkcji
1	100	0,00296	37520
2	100	0,00591	72440
3	100	0,00641	103300
4	100	0,00197	142220
5	100	0,00197	181280
6	100	0,00148	218700

Tabela 33: Zestawienie najlepszych wyników wszystkich trzech porównywanych algorytmów metaheurystycznych dla funkcji Griewanka - kryterium czasowe, Źródło: Opracowanie własne.

Drugie kryterium, pod kątem którego przeprowadzone zostały testy wskazuje już jednak w tabeli 36 jednoznacznie, iż lepsze rezultaty uzyskał algorytm genetyczny. Ponad dwukrotnie większa liczba odwołań metody roju cząstek do funkcji testowej w pierwszym kryterium, w kryterium drugim została zrównana. W tym przypadku przy takiej samej liczbie obliczeń funkcji testowej, algorytm genetyczny uzyskał wyniki bliższe minimum globalnemu niż metoda roju cząstek. Algorytm symulowanego wyżarzania w testach dotyczących obu kryteriów odniósł najgorsze rezultaty ze wszystkich porównywanych algorytmów heurystycznych. Warto jednak nadmienić, iż wyniki przez niego uzyskane oscylowały również blisko minimum globalnego.

Liczba odwołań do funkcji	Algorytm Genetyczny		
	Wielkość populacji	Wartość znalezionej minimum	Liczba generacji
1000	10	0,00462	100
2000	10	0,04365	200
3000	10	0,00396	300
4000	10	0,00788	400
5000	10	0,01948	500
6000	10	0,02440	600
1000	50	0,01314	20
2000	50	0,01897	40
3000	50	0,02859	60
4000	50	0,00395	80
5000	50	0,00468	100
6000	50	0,02538	120
1000	100	0,00391	10
2000	100	0,00395	20
3000	100	0,00000	30
4000	100	0,00198	40
5000	100	0,00000	50
6000	100	0,01380	60

Tabela 34: Zestawienie wyników algorytmu genetycznego dla funkcji Griewanka - kryterium liczby odwołań do funkcji testowej, Źródło: Opracowanie własne., Źródło: Opracowanie własne.

Liczba odwołań do funkcji	Metoda Roju Cząstek		
	Wielkość roju	Wartość znalezionej minimum	Liczba iteracji
1000	10	0,19106	100
2000	10	0,10885	200
3000	10	0,05545	300
4000	10	0,07227	400
5000	10	0,03778	500
6000	10	0,06479	600
1000	50	0,17494	20
2000	50	0,06023	40
3000	50	0,02455	60
4000	50	0,03154	80
5000	50	0,03950	100
6000	50	0,02333	120
1000	100	0,16603	10
2000	100	0,04679	20
3000	100	0,03319	30
4000	100	0,02646	40
5000	100	0,02729	50
6000	100	0,01758	60

Tabela 35: Zestawienie wyników metody roju cząstek dla funkcji Griewanka - kryterium liczby odwołań do funkcji testowej, Źródło: Opracowanie własne.

Symulowane Wyżarzanie			
Liczba odwołań do funkcji	Wartość znalezionej minimum		Liczba iteracji
1000	1,05495		1000
2000	0,29544		2000
3000	0,19756		3000
4000	0,18222		4000
5000	0,16877		5000
6000	0,15037		6000
Algorytm Genetyczny			
Liczba odwołań do funkcji	Wielkość populacji	Wartość znalezionej minimum	Liczba generacji
1000	100	0,00391	10
2000	100	0,00395	20
3000	100	0,00000	30
4000	100	0,00198	40
5000	100	0,00000	50
6000	100	0,01380	60
Metoda Roju Częstek			
Liczba odwołań do funkcji	Wielkość roju	Wartość znalezionej minimum	Liczba iteracji
1000	100	0,16603	10
2000	100	0,04679	20
3000	100	0,03319	30
4000	100	0,02646	40
5000	100	0,02729	50
6000	100	0,01758	60

Tabela 36: Zestawienie najlepszych wyników wszystkich trzech porównywanych algorytmów metaheurystycznych dla funkcji Griewanka - kryterium liczby odwołań do funkcji testowej, Źródło: Opracowanie własne.

6.4. Podsumowanie doświadczeń

Przeprowadzone doświadczenia wykonane zostały z myślą o wyrównaniu szans każdego z badanych algorytmów heurystycznych. Metody porównawcze opisane w 6.1 umożliwiły na podstawie ustalonych kryteriów, jednakowych dla wszystkich algorytmów, sprawdzić rezultaty przez nie uzyskane. Przez fakt różną specyfikę algoryt-

mów oraz posiadanie przez nich różnych parametrów, trudną kwestią było zrównanie ich szans oraz ich wyskalowanie. Podsumowując przeprowadzone doświadczenia w kontekście kryterium ustalonego czasu pracy algorytmu, w obrębie którego za zadanie ma znaleźć najmniejszą wartość badanej funkcji, algorytm genetyczny w trzech na sześć funkcji testowych uzyskał lepszy rezultat dla każdej wartości maksymalnego czasu. W dwóch kolejnych

7. Wnioski